Paxos/Raft 分布式一致性算法原理剖析及其在实战中的应用

基础架构事业群-数据库技术-数据库内核
圭多

目录 | Contents

Consensus Problem

✓ **定义：** The consensus problem requires agreement among a number of processes (or agents) for a single data value.

Consensus Problem

✓ 晚饭吃什么？

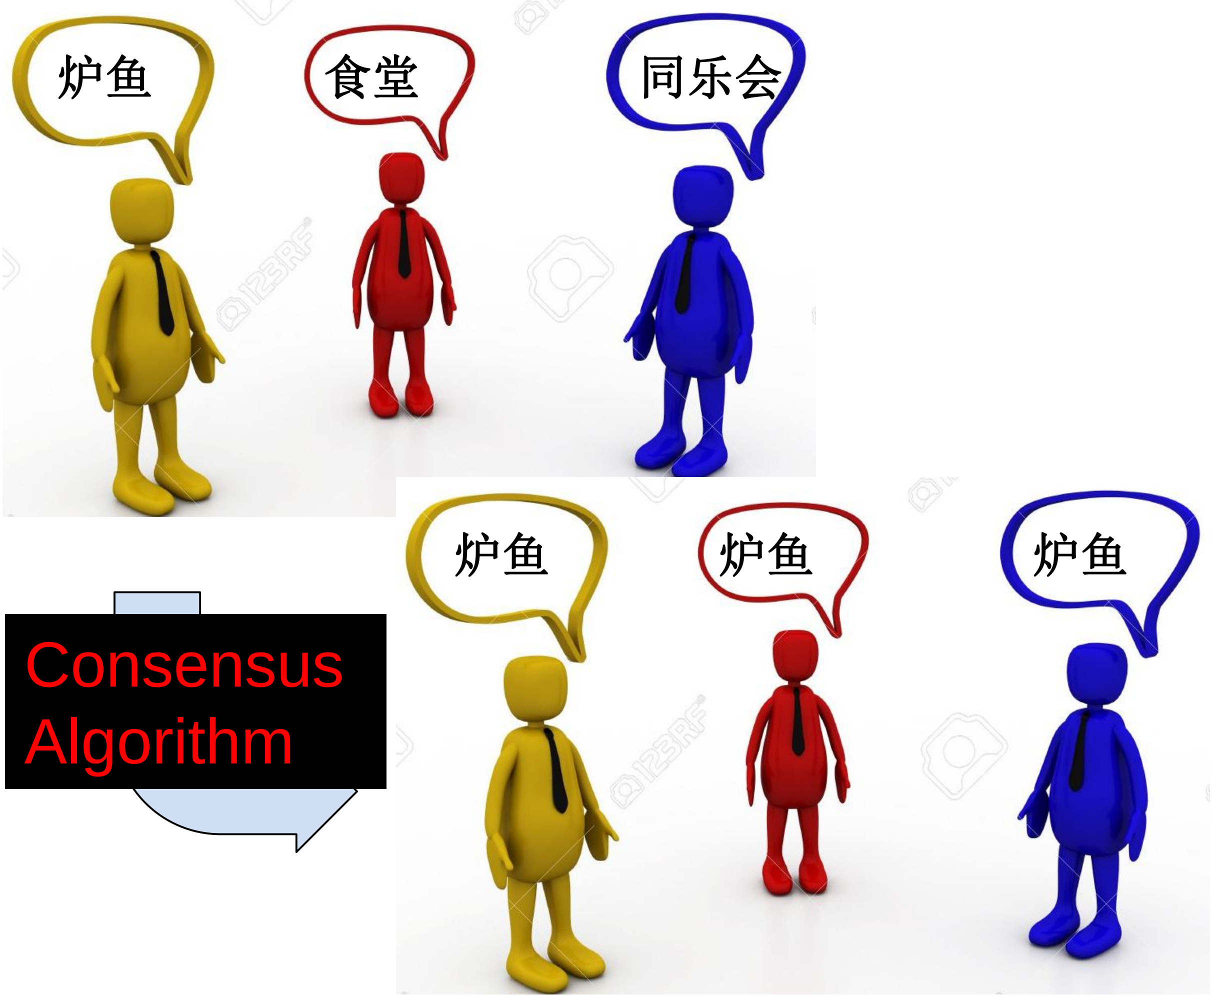

✓ **理解Consensus问题的关键**

- ✓ 绝对公平，相互独立：所有参与者均可提案，均可参与提案的决策
- ✓ 针对某一件事达成完全一致：一件事，一个结论
- ✓ 已经达成一致的结论，不可被推翻
- ✓ 在整个决策的过程中，没有参与者说谎

Consensus Algorithm：Basic Paxos

- ✓ **Basic Paxos**
  - ✓ 一个或多个Servers可以发起提案（Proposers）

  - ✓ 系统必须针对所有提案中的某一个提案，达成一致
    - ✓何谓达成一致？系统中的多数派同时认可该提案

  - ✓ 最多只能针对一个确定的提案达成一致

- ✓ **Liveness (只要系统中的多数派存活，并且可以相互通信)**
  - ✓ 整个系统一定能够达成一致状态，选择一个确定的提案

Basic Paxos：Components

- ✓ **Proposers**
  - ✓ Active：提案发起者（value）
  - ✓ 处理用户发起的请求
- ✓**Acceptors**
  - ✓ Passive：参与决策，回应Proposers的提案
  - ✓ 存储accept的提案（value），存储决议处理的状态
- ✓**Learners**
  - ✓ Passive：不参与决策，从Proposers/Acceptors学习最新达成一致的提案（value）

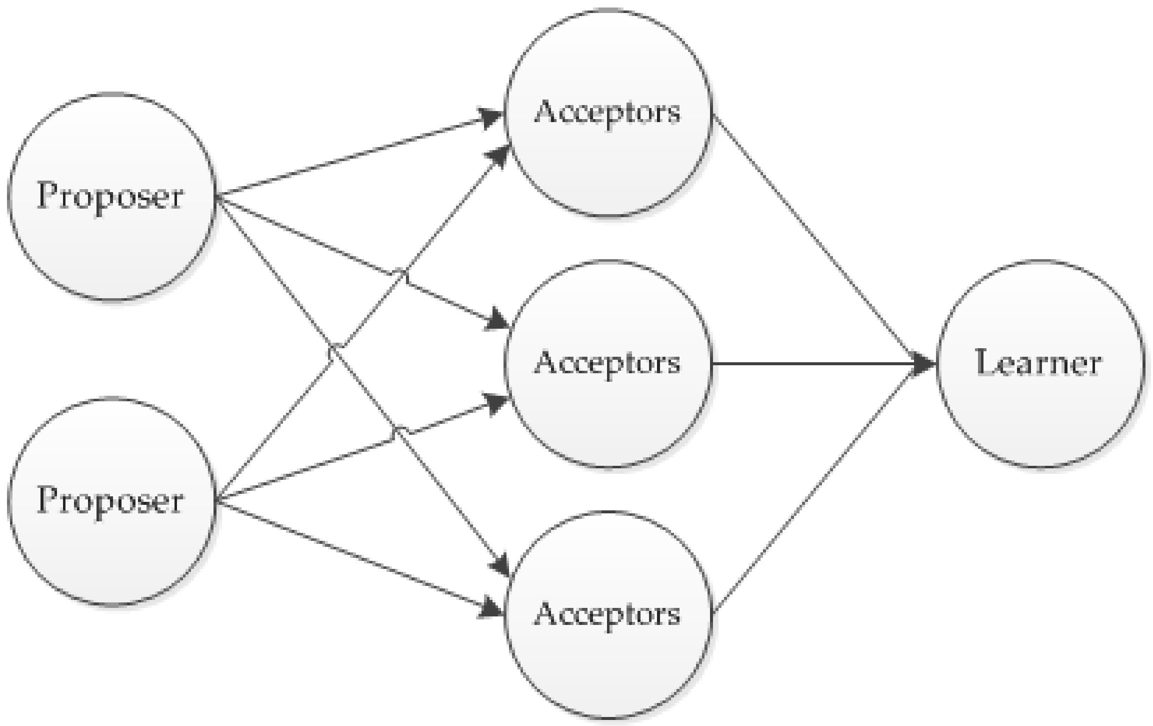

✓**本文接下来的部分，一个Server同时具有Proposer和Acceptor两种角色，Learner角色逻辑简单，暂时不讨论**

Basic Paxos：Acceptors如何决策？

- ✓ **Accept First**
  - ✓ Acceptor仅仅接受其收到的第一个value

- ✓**Accept Last**
  - ✓ Acceptor接受其收到的所有value，新的覆盖老的

Accept First： Split Votes

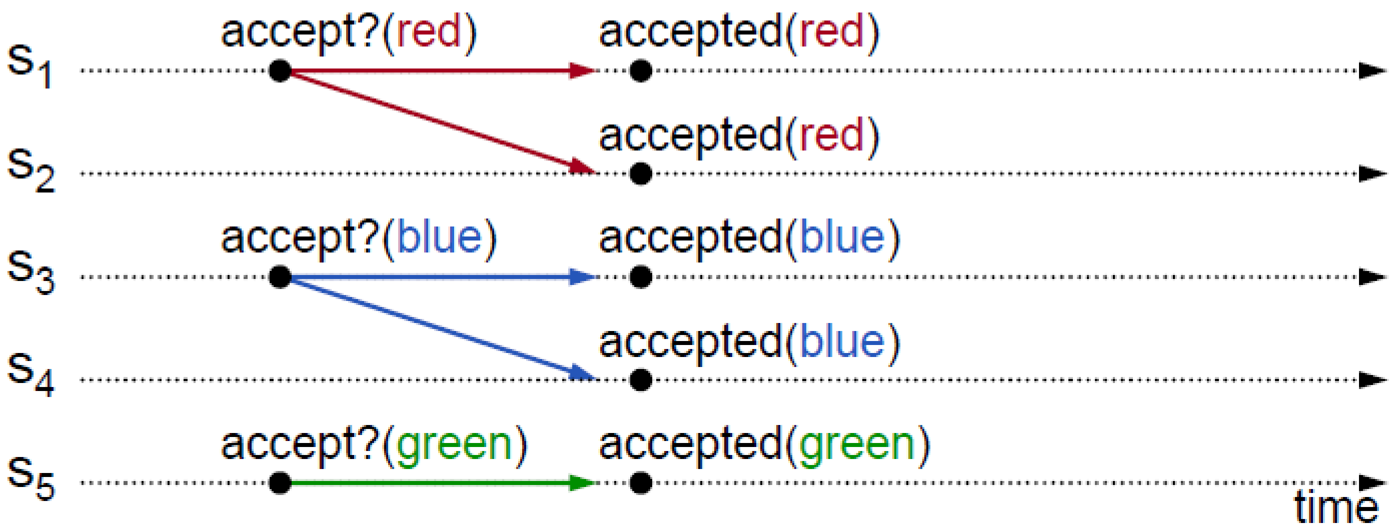

✓**对于并发的proposals，同时accept多个value，违背原则：**
- ✓ 系统中的多数派同时认可该提案
- ✓ 最多只能针对一个确定的提案达成一致

Accept Last：Conflicting Choices

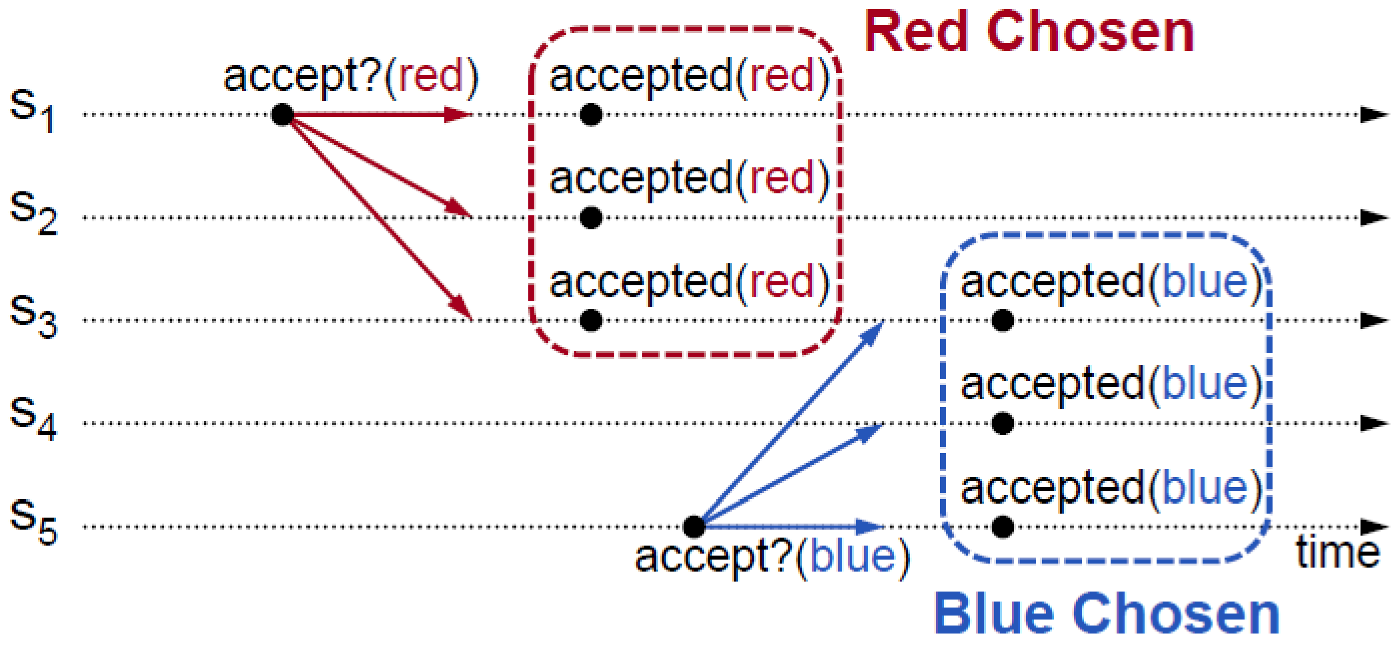

✓**对于并发的proposals，先后accept多个value，违背原则：**

✓ 最多只能针对一个确定的提案达成一致

Accept Last：Conflicting Choices（2）

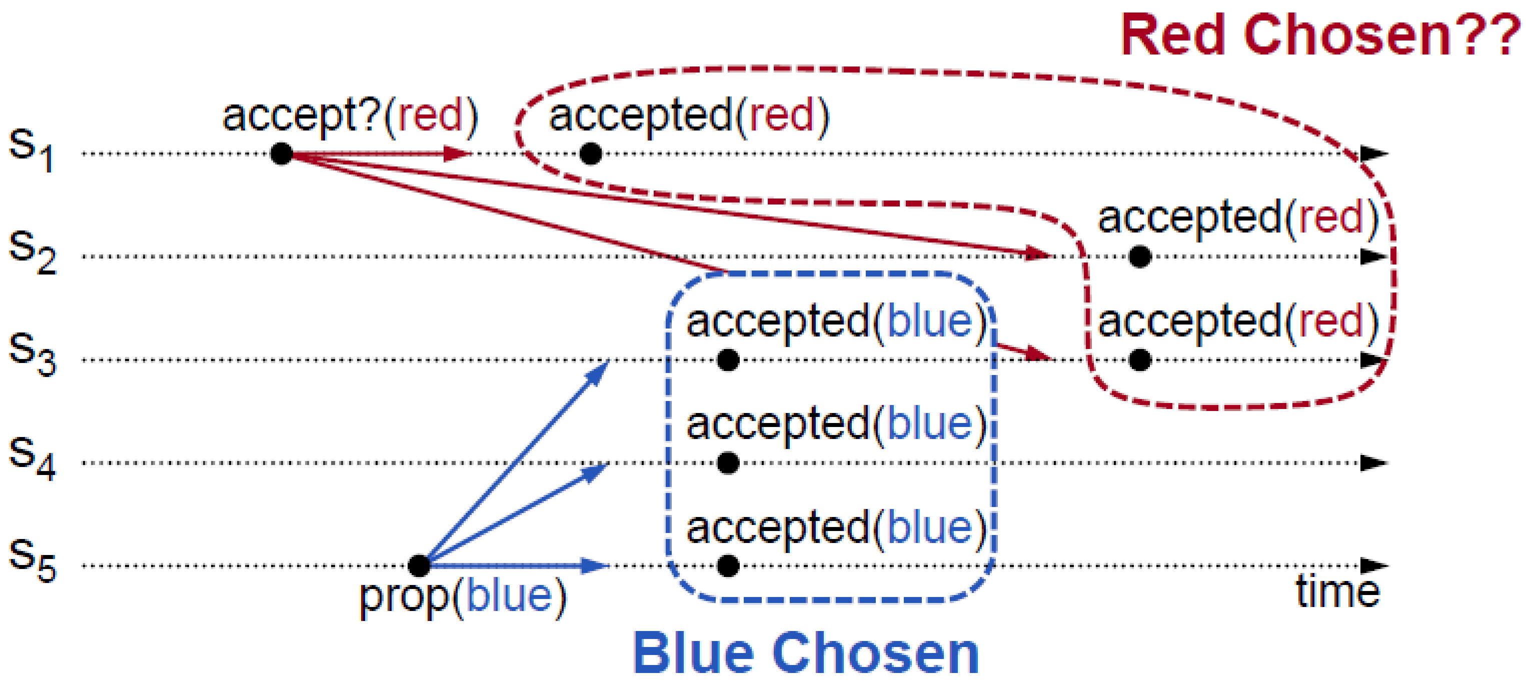

✓**对于并发的proposals，先后accept多个value，违背原则：**

✓ 最多只能针对一个确定的提案达成一致

Basic Paxos： Acceptors如何决策？

- ✓ **Accept First**
  - ✓ Acceptor仅仅接受其收到的第一个value

- ✓**Accept Last**
  - ✓ Acceptor接受其收到的所有value，新的覆盖老的

✓**Accept First，Accept Last都有问题。那Basic Paxos如何解决这些问题？如何实现Consensus？**

Basic Paxos：一阶段至两阶段

- ✓ **一阶段Accept**
  - ✓ **Accept First，Accept Last**都不行
  - ✓ 参考分布式事务，两阶段提交（2PC）？

- ✓ **两阶段Accept**
  - ✓ 第一阶段：Propose阶段。Proposers向Acceptors发出Propose请求，Acceptors针对收到的Propose请求进行Promise承诺
  - ✓ 第二阶段：Accept阶段。收到多数派Acceptors承诺的Proposer，向Acceptors发出Accept请求，Acceptors针对收到的Accept请求进行接收处理
  - ✓ 第三阶段（可优化）：Commit阶段。发出Accept请求的Proposer，在收到多数派Acceptors的接收之后，标志着本次Accept成功。向所有Acceptors追加Commit消息

Basic Paxos：Proposal ID

- ✓ **Propose阶段**
  - ✓ **Proposal ID**：唯一标识所有的Propose。包括：不同Proposers发出的Propose，同一Proposer发出的不同Propose。
- ✓**Proposal Number（唯一性）**

Proposal ID

Round Number	Server Id

  - ✓ **Round Number：**每个节点存储本节点曾经看到过的最大值：maxRound
  - ✓ **Server Id：**系统中每个节点的唯一标识
  - ✓ **Propose：**获取当前节点的maxRound，自增1，然后加上本节点的Server Id，作为本次的Proposal ID
- ✓**Proposal ID（特性）**
  - ✓ Proposal ID**全局唯一递增**，大小代表了优先级。优先级的作用？

Basic Paxos：Propose阶段（文字版）

- ✓ **Proposer 发送 Propose**
  - ✓ Proposer 生成全局唯一且递增的Proposal ID，向集群的所有机器发送 Propose，这里无需携带提案内容，只携带Proposal ID即可

- ✓**Acceptor 应答 Propose**
  - ✓ Acceptor 收到Propose后，做出“**两个承诺，一个应答**”
  - ✓ **两个承诺**
    - ✓第一，不再应答 Proposal ID 小于等于（**注意：这里是 <=** ）当前请求的 Propose
    - ✓第二，不再应答 Proposal ID 小于（**注意：这里是 <** ）当前请求的 Accept请求
  - ✓ **一个应答**
    - ✓返回已经 Accept 过的提案中 Proposal ID 最大的那个提案的Value和accepted Proposal ID，没有则返回空值

Basic Paxos：Accept阶段（文字版）

- ✓ **Proposer 发送 Accept**
  - ✓ **“提案生成规则”**：Proposer 收集到多数派的Propose应答后，从应答中选择存在提案Value的并且同时也是Proposal ID最大的提案的Value，作为本次要发起 Accept 的提案。如果**所有应答的提案Value均为空值**，则可以自己随意决定提案Value。然后携带上当前Proposal ID，向集群的所有机器发送 Accept请求

- ✓**应答 Accept**
  - ✓ Acceptor 收到 Accpet 请求后，检查不违背自己之前作出的“两个承诺”情况下，持久化当前 Proposal ID 和提案Value。最后 Proposer 收集到多数派的Accept应答后，形成决议

Basic Paxos：细节（算法版）

Proposers

1) Choose new proposal number n

2)Broadcast Prepare(n) to all servers

4)When responses received from majority:

If any acceptedValues returned, replace value with acceptedValue for highest acceptedProposal

5)Broadcast Accept(n, value) to all servers

6)When responses received from majority:

Any rejections (result > n)? goto (1)

Otherwise, value is chosen

Acceptors

3)Respond to Prepare(n):

If n **>** minProposal then minProposal = n

Return(acceptedProposal, acceptedValue)

6)Respond to Accept(n, value):

If n ≥ minProposal then acceptedProposal = minProposal = n acceptedValue = value

Return(minProposal)

✓Acceptors must record minProposal, acceptedProposal, and acceptedValue on stable storage

Basic Paxos：Examples (1)

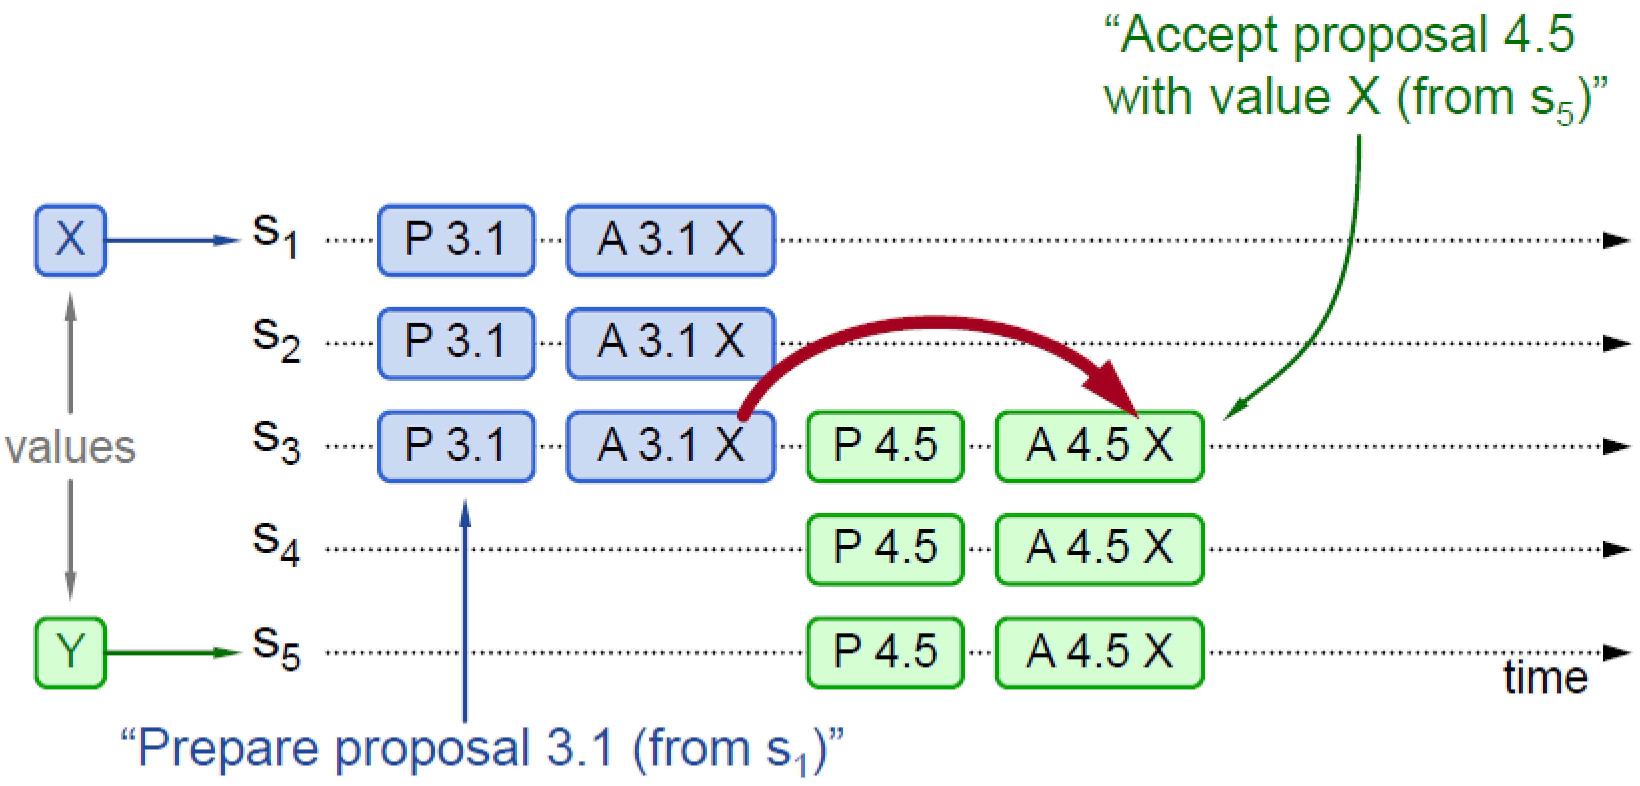

- ✓**P 3.1**
  - ✓ Proposal ID：round number(3), server id(1)
- ✓**P 3.1达成多数派，其Value(X)被Accept，然后P 4.5学习到Value(X)，并Accept**

Basic Paxos：Examples（2）

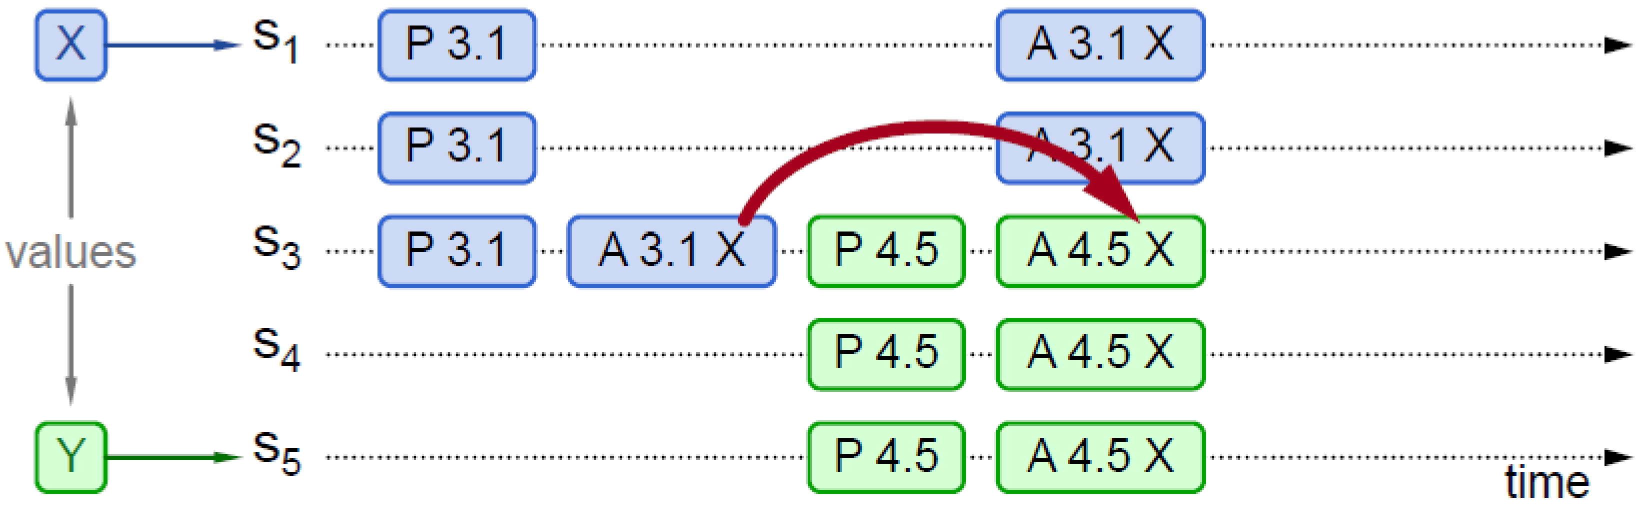

✓P 3.1没有被多数派Accept（只有S3 Accept），但是被P 4.5学习到，P 4.5将自己的Value由Y替换为X，Accept（X）

Basic Paxos：Examples（3）

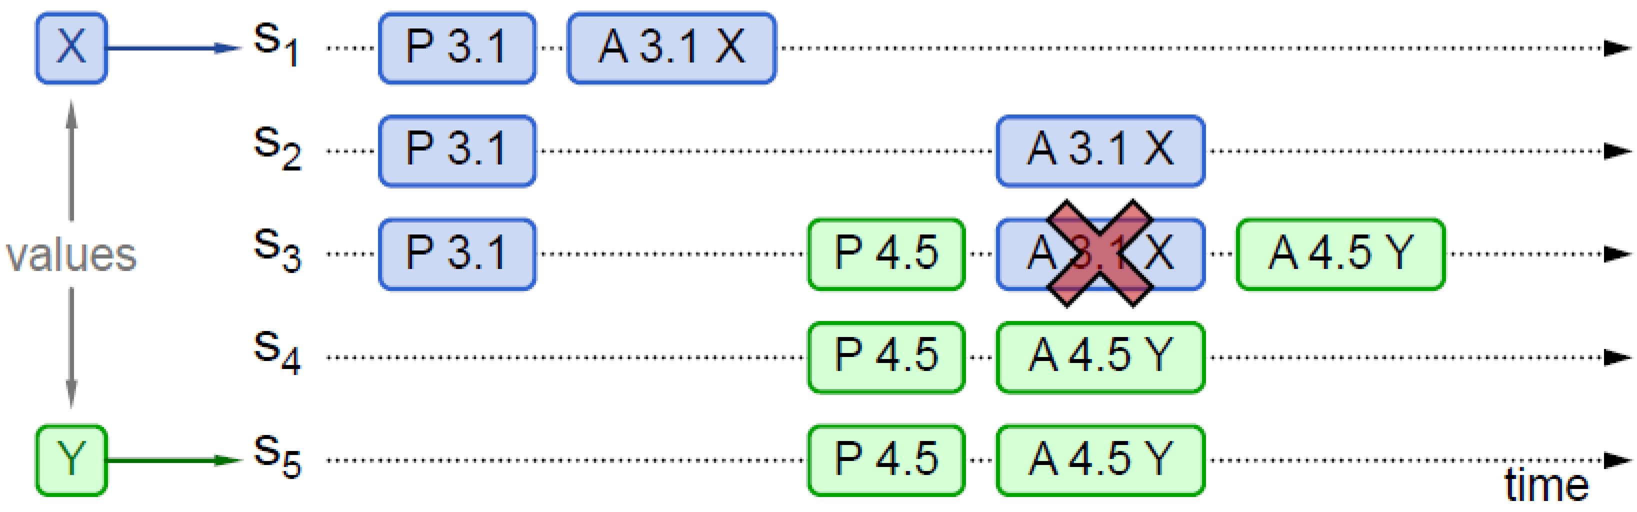

✓**P 3.1没有被多数派Accept（只有S1 Accept），同时也没有被P 4.5学习到。由于P 4.5 Propose的所有应答，均未返回Value，则P 4.5可以Accept自己的Value（Y）**

✓**后续P 3.1的Accept（X）会失败，已经Accept的S1，会被覆盖**

Paxos一个异常场景的分析

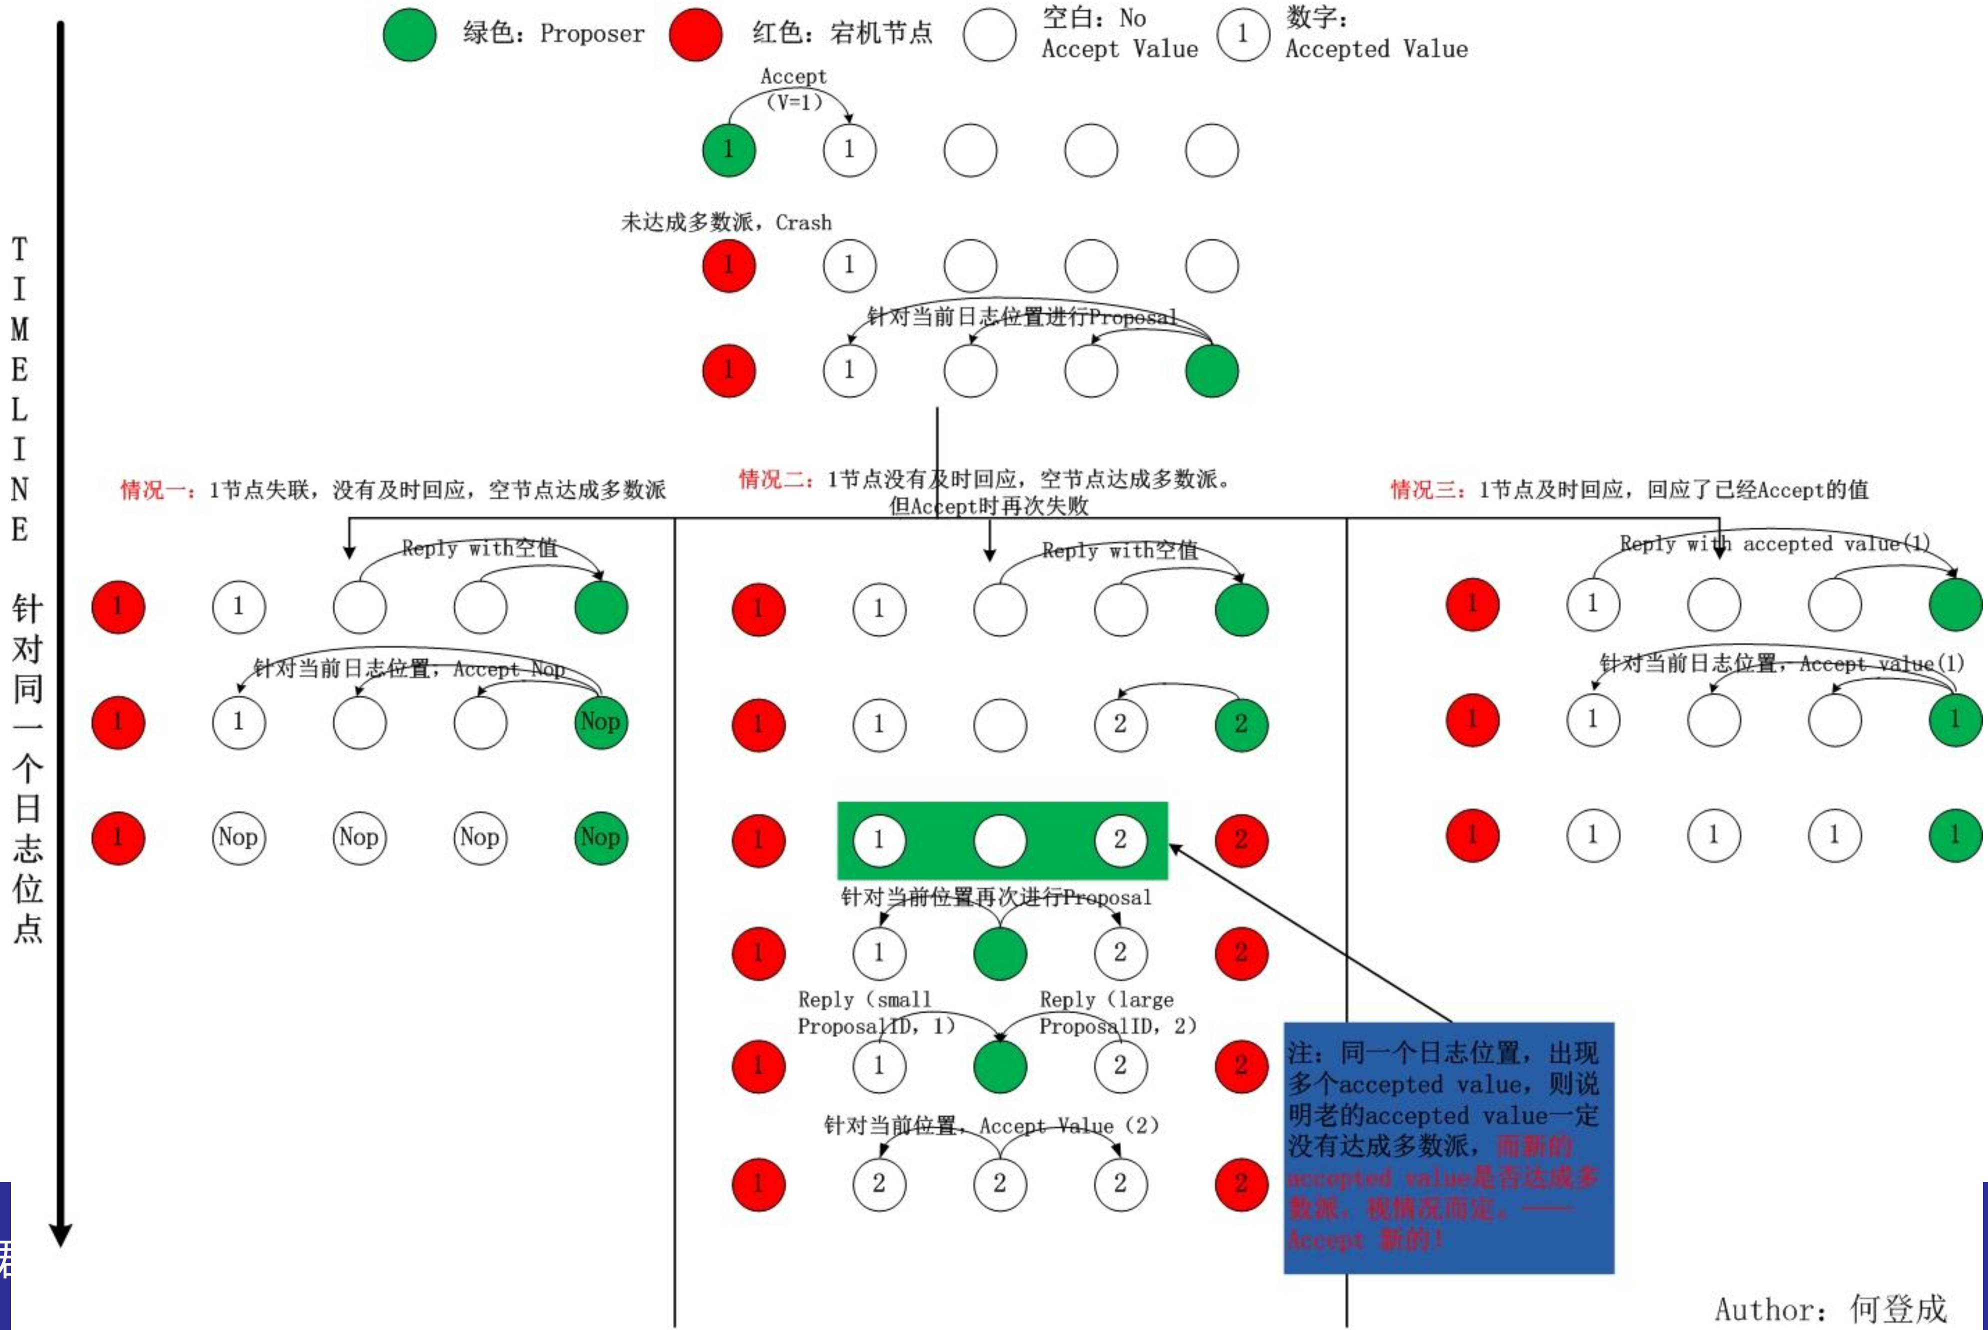

Basic Paxos：Livelock（活锁）

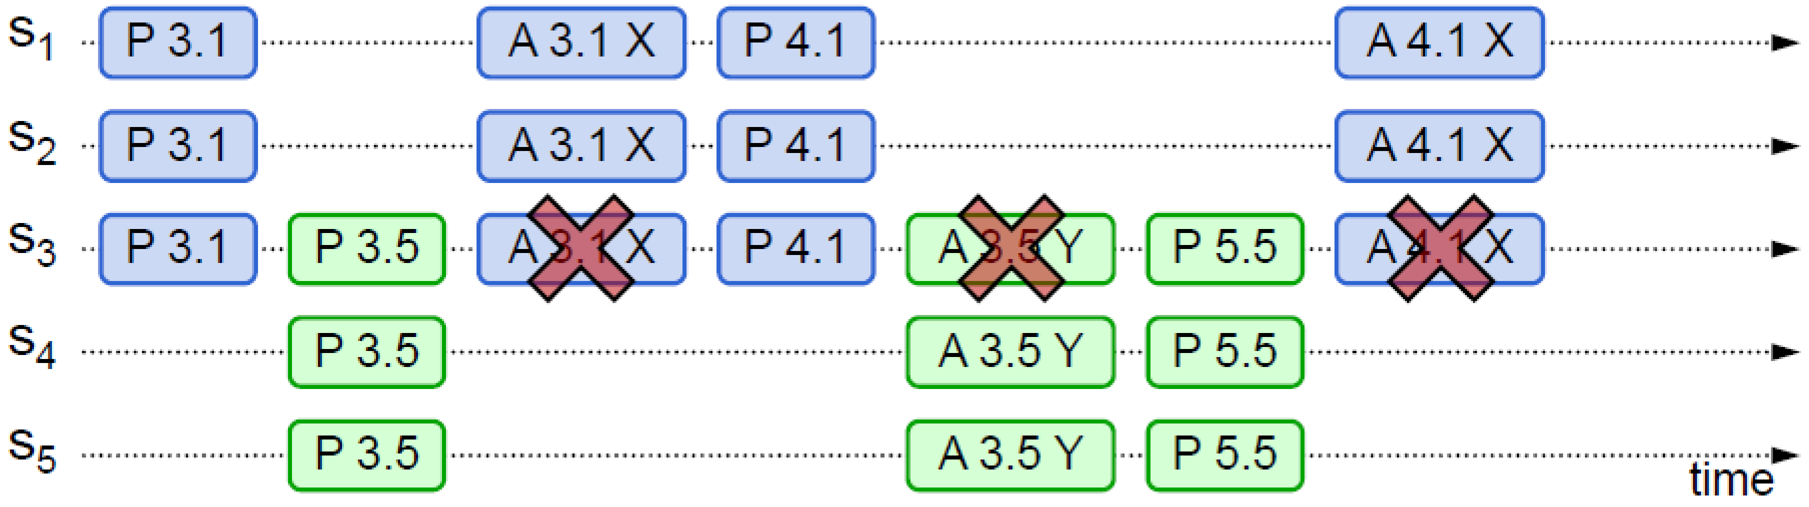

- ✓**回顾两个承诺之一**
  - ✓ 不再应答 Proposal ID 小于等于当前请求的 Propose。意味着：需要应答Proposal ID大于当前请求的Propose
- ✓**两个Proposers交替Propose成功，Accept失败，形成活锁（Livelock）**

Basic Paxos：阶段总结

✓**Now，what we learn？**

- ✓ 学会了Basic Paxos，能用Basic Paxos解决Consensus问题，**确定一个提案，确定一个取值**

✓**Now，what we can do？**

- ✓ 决定本届美国总统选谁（**两个Proposers**：民主党、共和党；**两个Value**：Hillary、Trump；但我们好像是Learner角色...）
- ✓ 决定今晚吃什么？
- ✓ 一主多从架构，主宕机，决定选哪个从当新主

✓**Now， what we can’t do？**

- ✓ **如果想确定连续多个提案，确定连续多个值，Basic Paxos搞不定了...**

Consensus：From Basic to Multi-Paxos

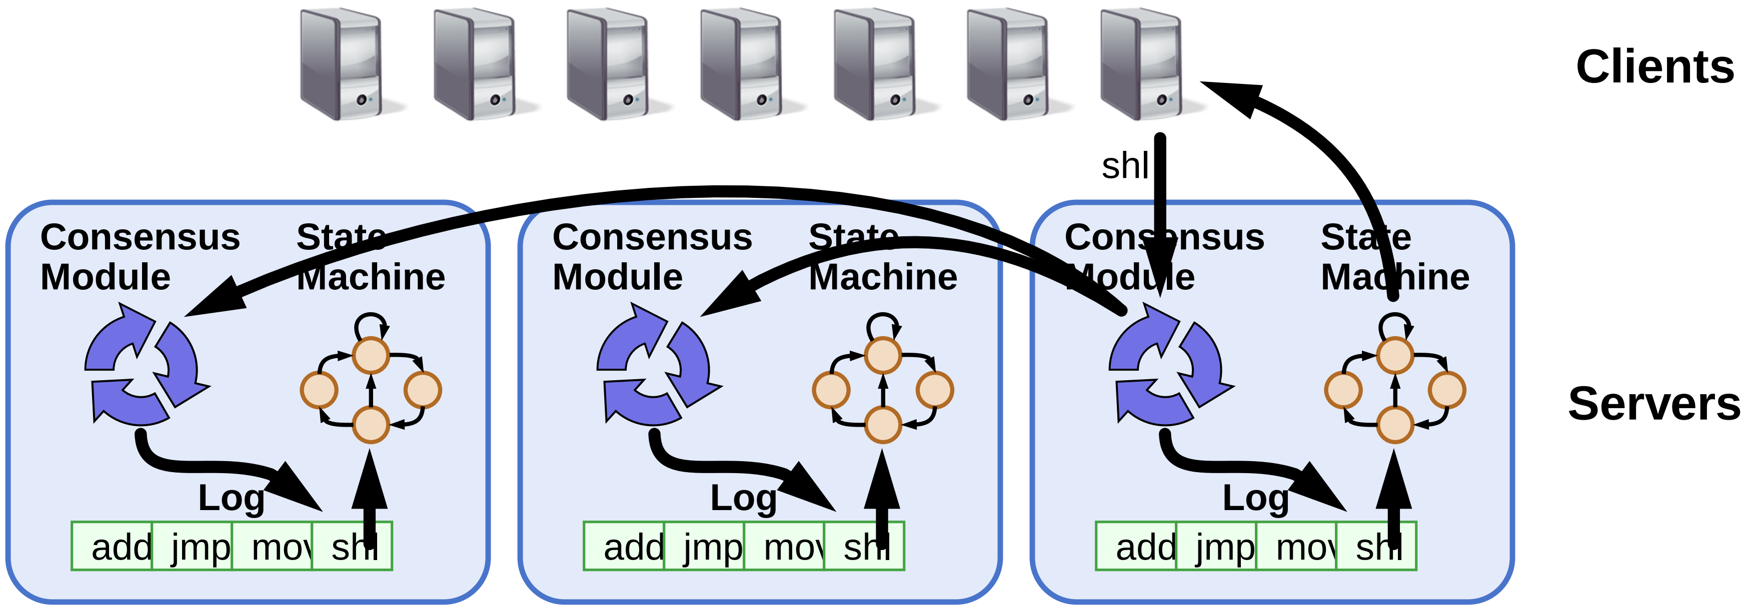

✓**Consensus Module**：从Basic Paxos的决策单个Value，到连续决策多个Value。同时确保每个Servers上的顺序完全一致

✓ **相同顺序执行命令，所有Servers状态一致**

✓ **只要多数节点存活，Server能提供正常服务**

Multi-Paxos

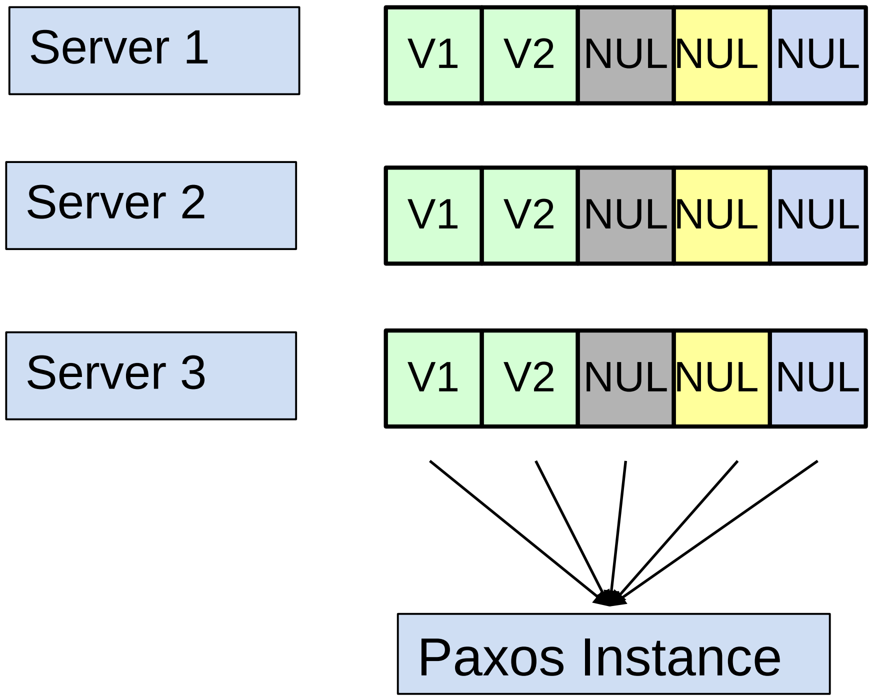

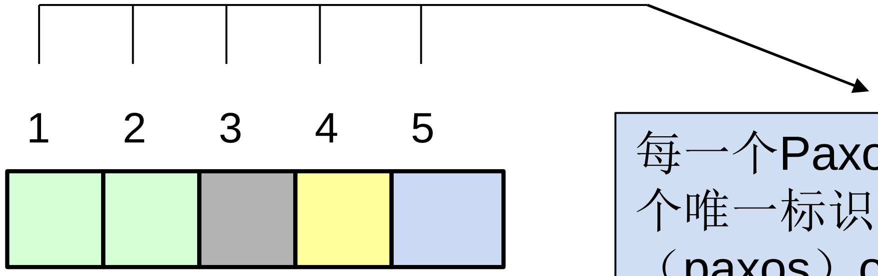

每一个Paxos Instance，都有一个唯一标识：**instance Id**（paxos）or **log Index**（Raft）

此文后面部分，均称之为：**log Index**

- ✓ **(Basic) Multi-Paxos**
  - ✓ 针对每一个Paxos Instance使用完整的Paxos算法，确保系统中的每一个Server，Server上的每一个Paxos Instance都完全一致

（Basic）Multi-Paxos的缺点、横空出世的Raft

- ✓ **（Basic）Multi-Paxos：缺点**
  - ✓ 难以理解、难以正确实现（gap between theory and practice）
    - ✓ Google Paxos Made Live： Despite the existing literature on the subject, building a production system turned out to be a non-trivial task…
  - ✓ 多点可写（Proposers），性能较差
    - ✓ 每个写入两个RPCs；多点可写，写入冲突
    - ✓ Google MegaStore：Limiting that rate to a few writes per second per entity group yields insignificant conflict rates. For apps whose entities are manipulated by a small number of users at a time, this limitation is generally not a concern…
- ✓**Raft（Leader based Consensus Algorithm）**
  - ✓ Diego Ongaro , Stanford University：In Search of an Understandable Consensus Algorithm（2014）

Raft（特点）

✓**Raft（Leader Based）**

- ✓ 系统存在一个Leader角色（Proposer），接受Clients发过来的所有读写请求
- ✓ Leader负责与所有的Followers（Acceptors）通信，将提案/Value/变更复制到所有Followers，同时收集多数派Followers的应答
- ✓ 少数派宕机，不会影响系统整体的可用性
- ✓ Leader日常维护与所有Followers的心跳
- ✓ Leader宕机，会触发系统自动重新选主，选主期间系统对外不可服务

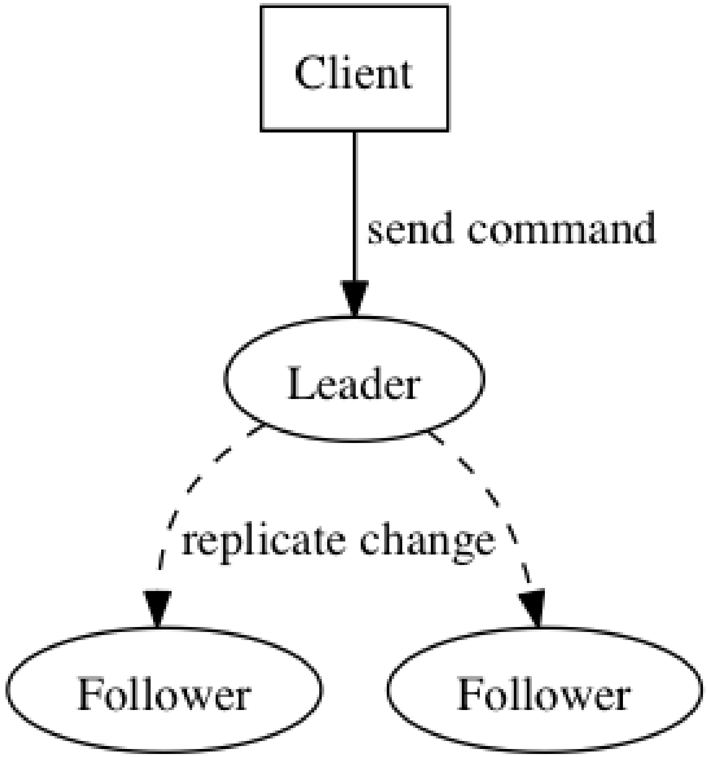

关于Leader角色的解读（从Paxos的视角）

- ✓ **Paxos Propose的意义**
  - ✓ **Block old proposals**
  - ✓ **Find out about (possibly) accepted values**

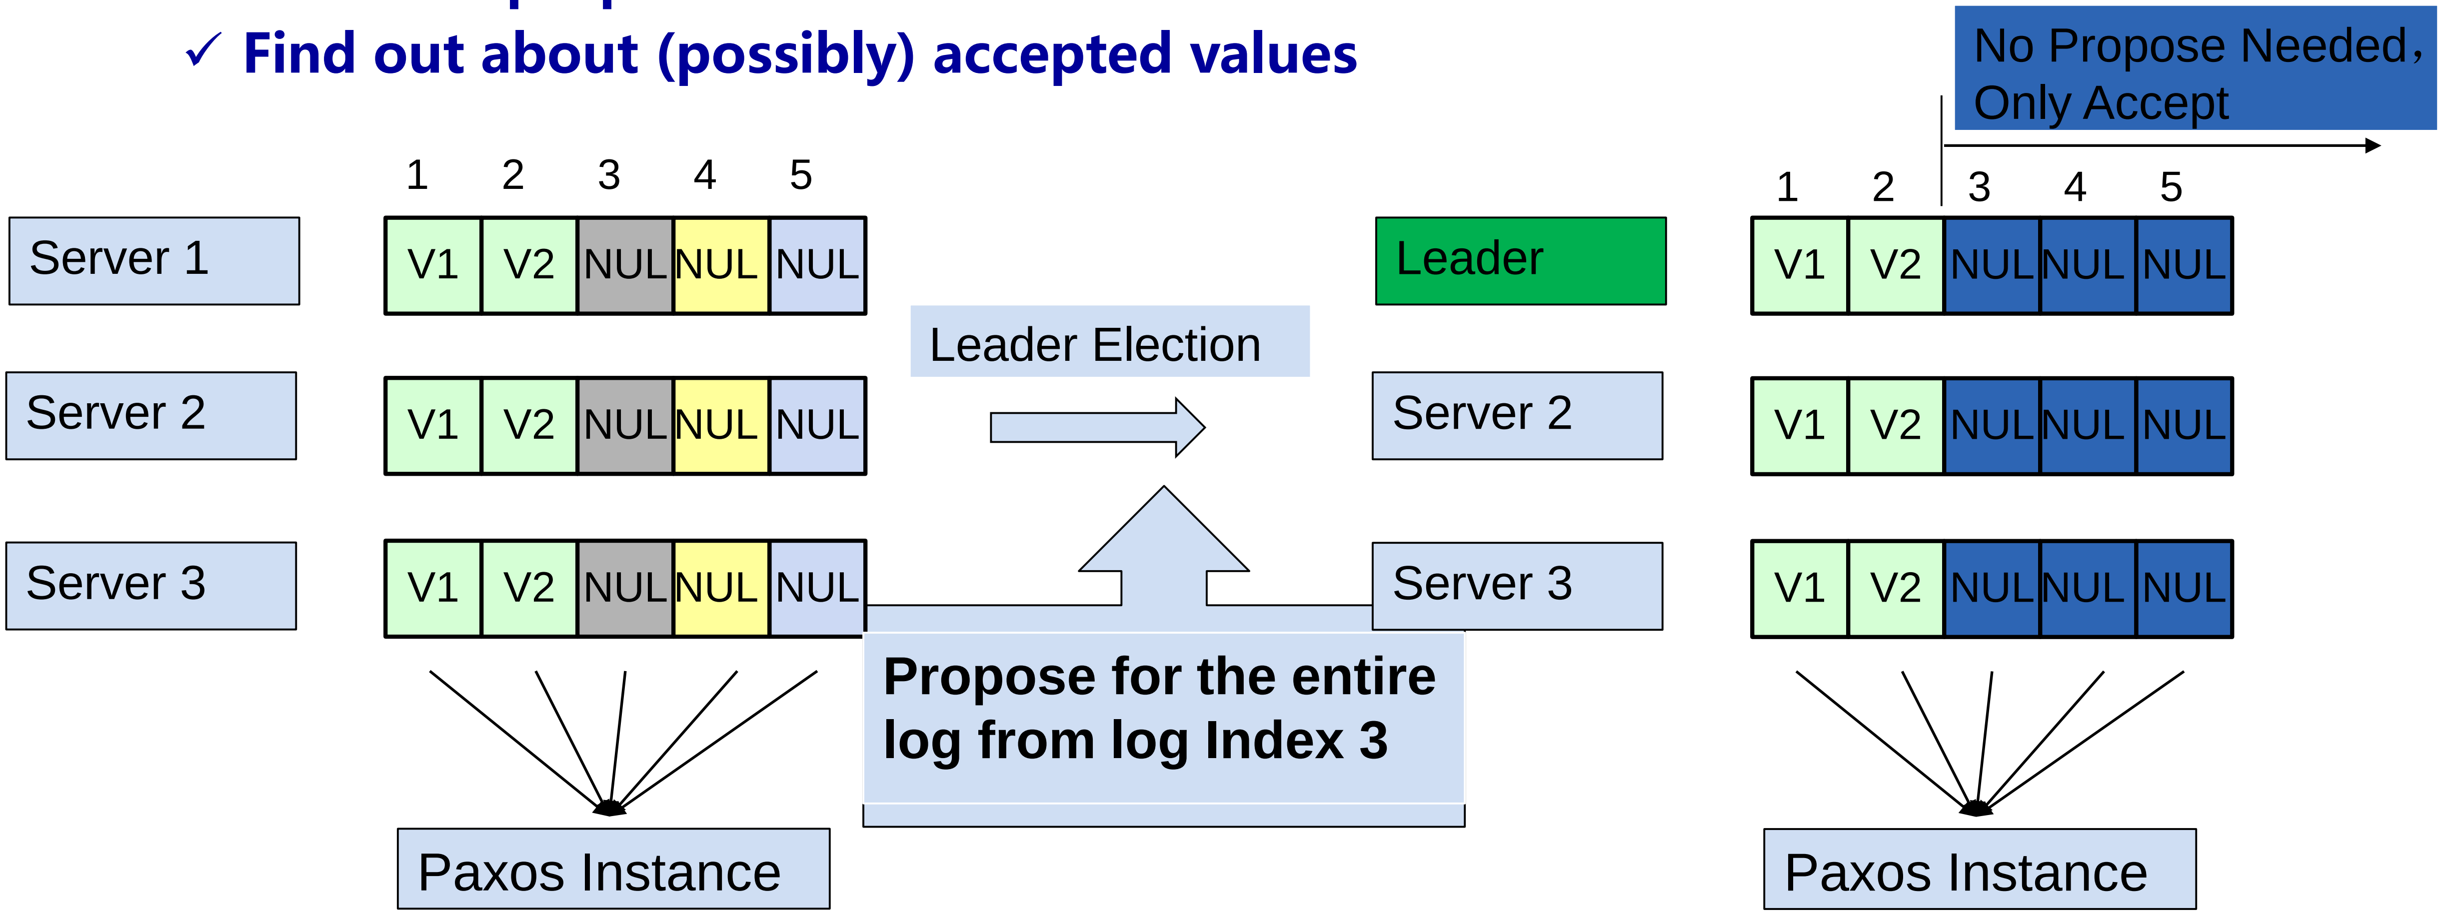

Raft基本概念

✓Server状态

- ✓ Follower： Completely Passive。接收来自Leader或者是Candidate的message，并响应
- ✓ Leader：used to elect a new leader
- ✓ Candidate： handles all client interactions, log replication

✓Message类型

- ✓ RequestVote
- ✓ AppendEntries（HeartBeat）
- ✓ InstallSnapshot

✓Terms

- ✓ 时间轴被划分为多个Terms
- ✓ Term ID：每个Term的唯一标识，按时间轴递增
- ✓ 新Term随着Leader选举而开始
- ✓ 每个Term，最多只有一个Leader（可能没有Leader，split vote）

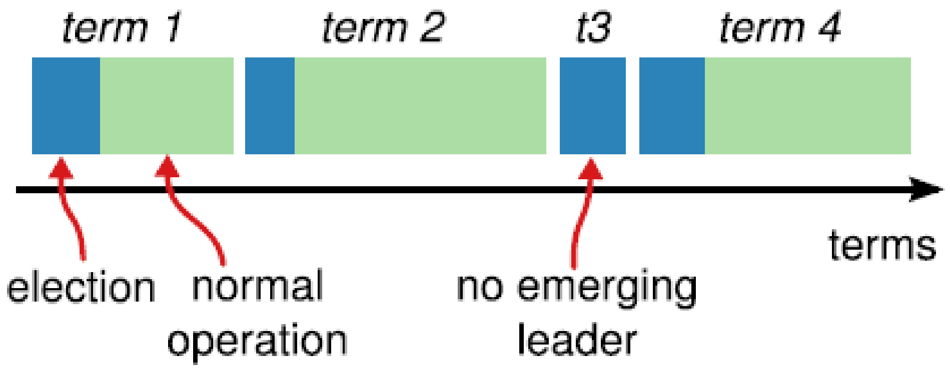

Raft功能分解

- ✓ **Leader选举（Leader Election）**
- ✓**日志同步（Log Replication）**
- ✓**Commit Index推进（Advance Commit Index）**
- ✓**崩溃恢复（Crash Recovery）**
- ✓**成员变更（Membership Change）**

Raft——Leader Election

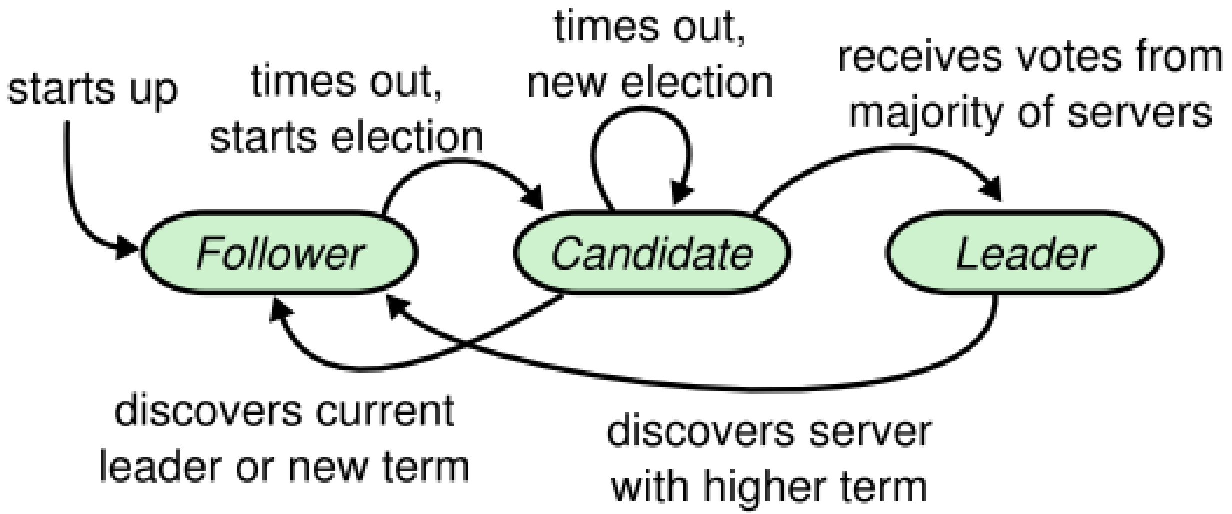

- ✓ **Leader Election关键点**
  - ✓ **超时驱动**：Heartbeat Message / Election Timeout
  - ✓ **随机开始**：降低选举碰撞（Vote Split）导致的无主概率

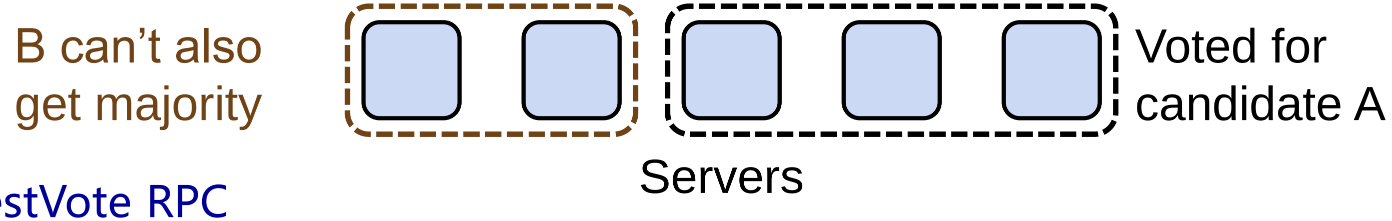

  - ✓ **选举动作**：current term++，然后发出RequestVote RPC
  - ✓ **Safty**：同一Term，最多只会选出一个Leader，可以没有Leader

Raft——Leader Election（注意事项）

- ✓ **Raft Leader Election 注意事项**
  - ✓ Leader Election与各节点的**绝对时间无关**，但是跟相对时间有关
    - ✓ 意味着：Servers间的绝对时间可以不相同，但是时间的流失速度需要基本一致（偏差不大）
  - ✓ **影响Raft选举成功率的几个时间相关参数**
    - ✓ **RTT（Round Trip Time）**：网络延时
    - ✓ **Heartbeat Timeout**：心跳间隔
    - ✓ **Election Timeout**：Leader与Followers间通信超时触发选举时间
    - ✓ **MTBF（Meantime Between Failure）**：Servers连续常规故障时间间隔

RTT << Heartbeat Timeout < Election Timeout（ET） << MTBF

- ✓ 随机选主触发： s_{et} = Random（ET，2ET）；
- ✓ 选举碰撞概率： $P(\Delta s_{et} <= RTT)$

Raft——Log Replication

✓**Raft日志格式**

- ✓ **Raft Log（TermID，LogIndex，LogValue）**
- ✓ TermID，LogIndex用来标识日志的唯一性

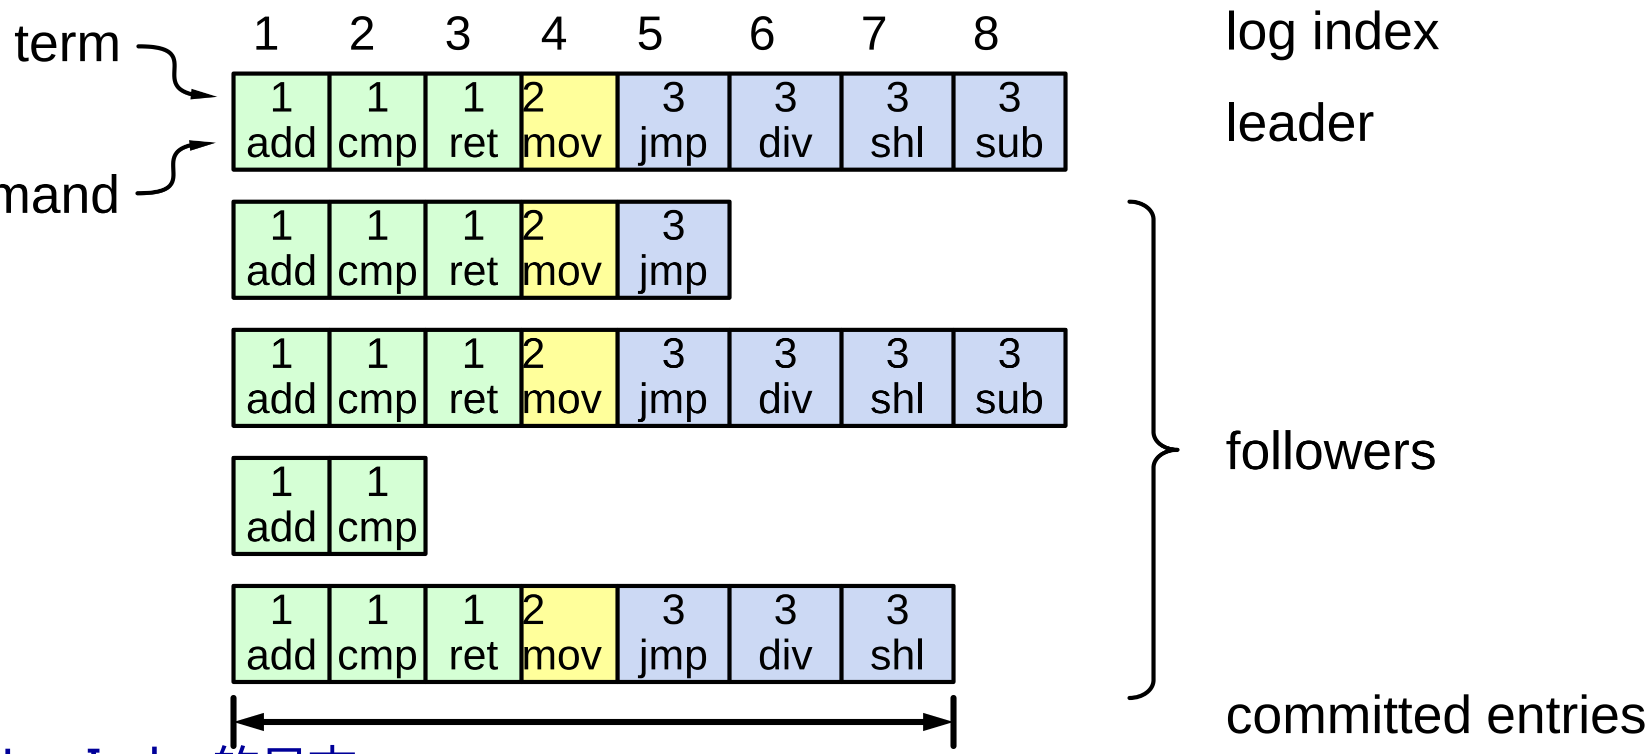

✓**Log Replication关键点**

- ✓ 连续性：Raft日志不能存在空洞
- ✓ 有效性：
  - ✓ 不同节点，拥有相同Term和LogIndex的日志Value一定相同
  - ✓ Leader上的日志都是有效的
  - ✓ Followers日志是否有效，通过与Leader日志对比来判断。How？

Raft——Folowers日志有效性检查

✓Followers日志有效性检查

- ✓ AppendEntries RPC中，除了待复制的日志之外，还带有前一个日志的唯一标识（prevTermID，prevLogIndex）
- ✓ Follower在收到AppendEntries RPC之后，检查（prevTermID，prevLogIndex）与本地的日志是否Match：Match则接受，不match则拒绝
- ✓ 递归推导，证明Follower上（prevTermID，prevLogIndex）之前的所有日志，与Leader均相同

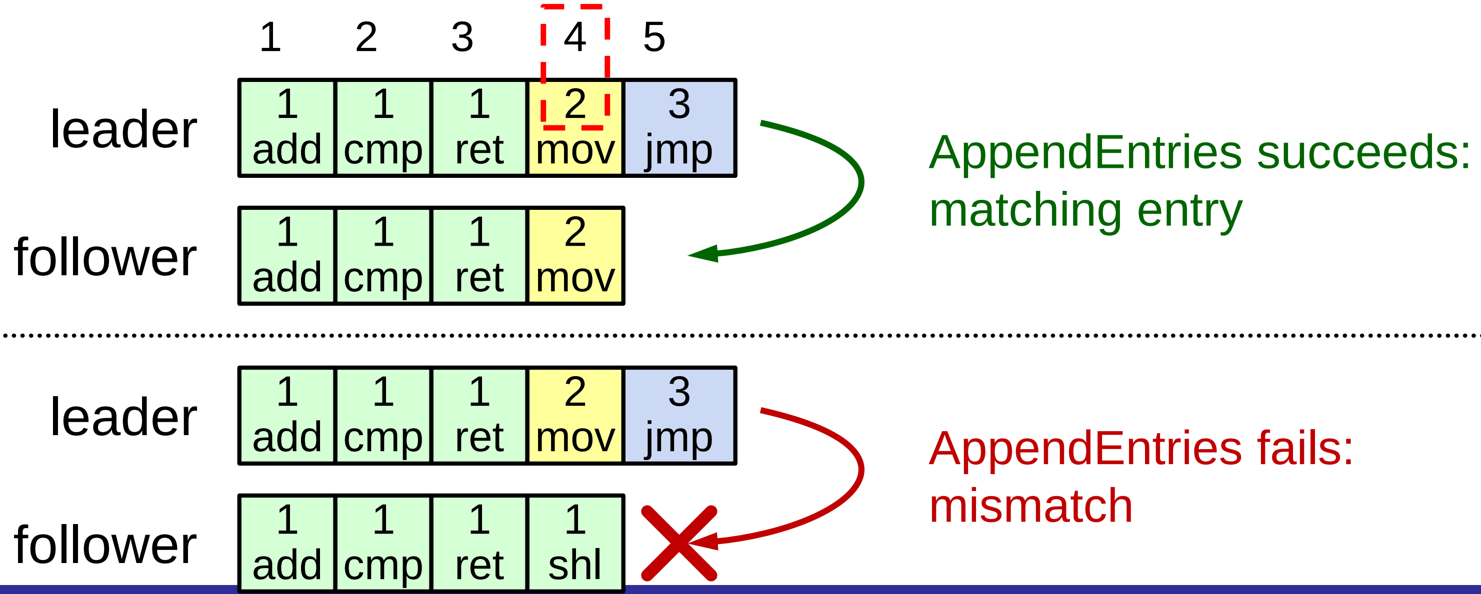

Raft——Folowers日志修复

✓Followers日志修复

- ✓ Followers上，不满足有效性检查的日志，如何修复？

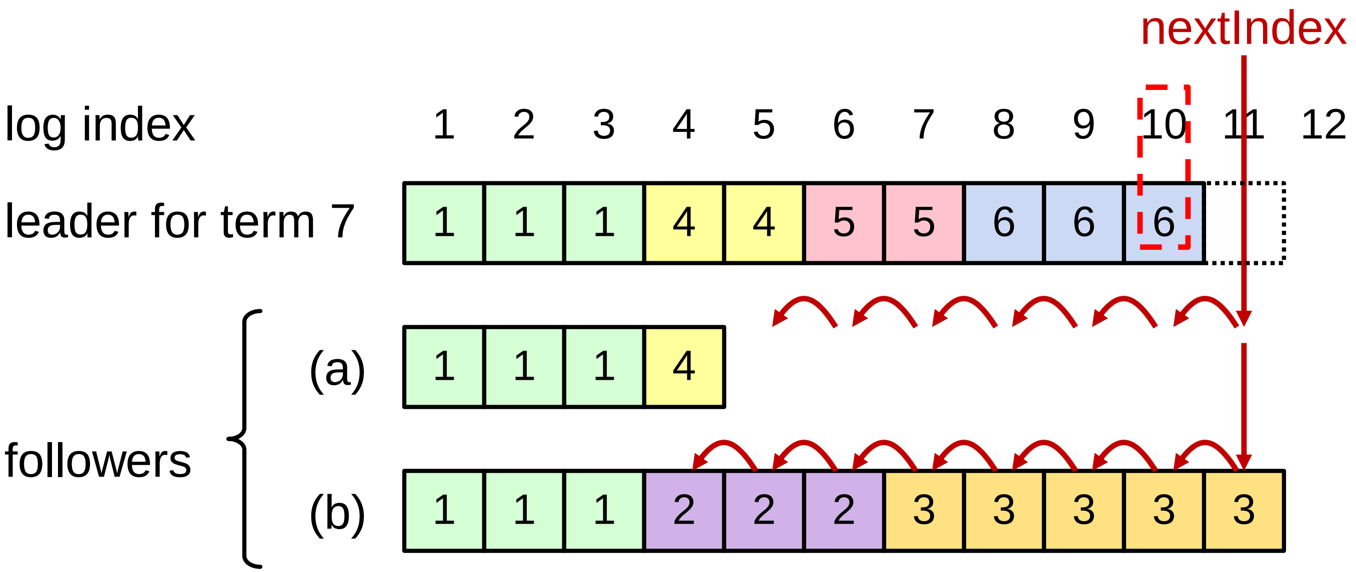

Raft日志同步——Follower处理逻辑

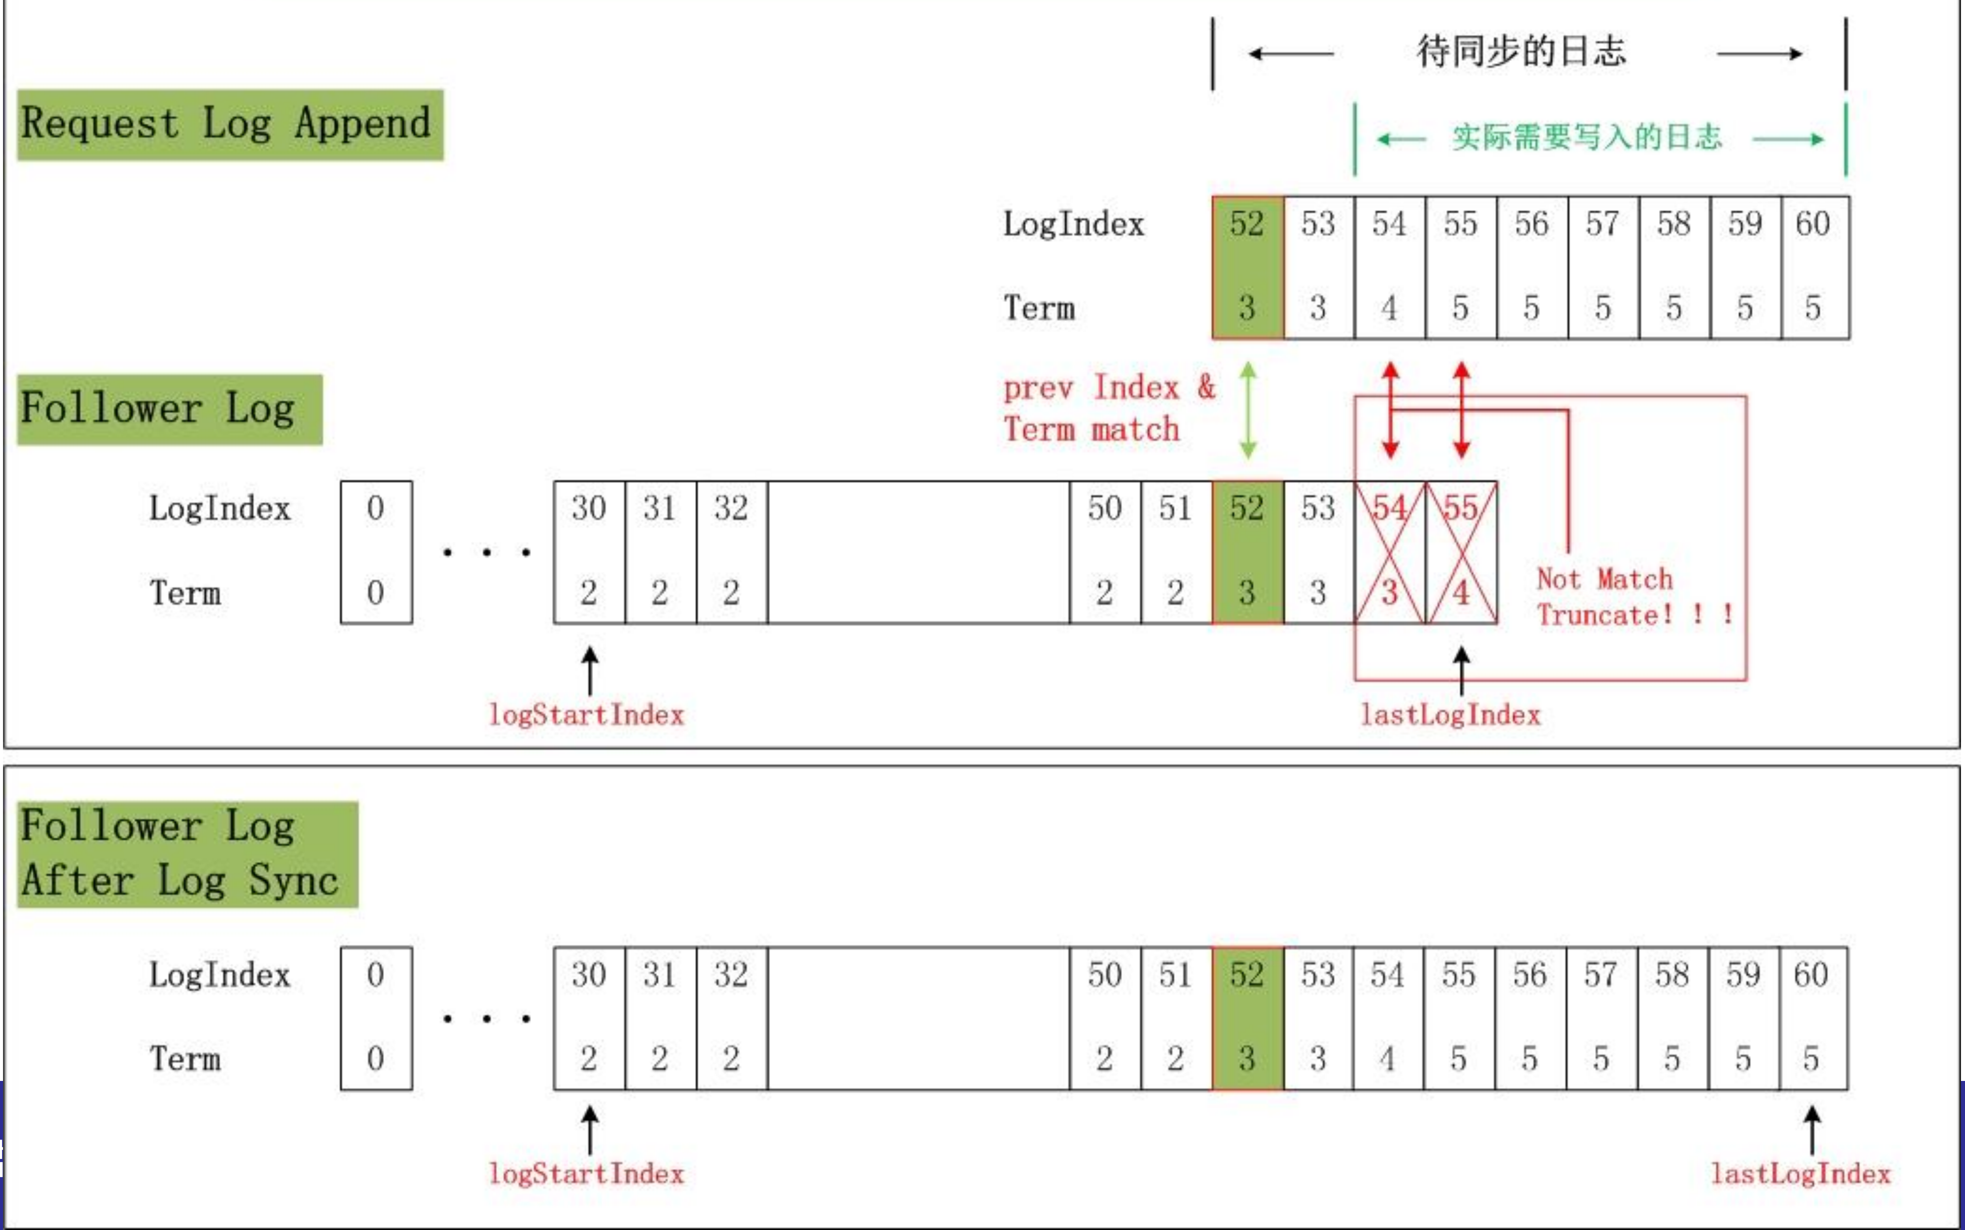

Log Replication——Raft vs Multi-Paxos

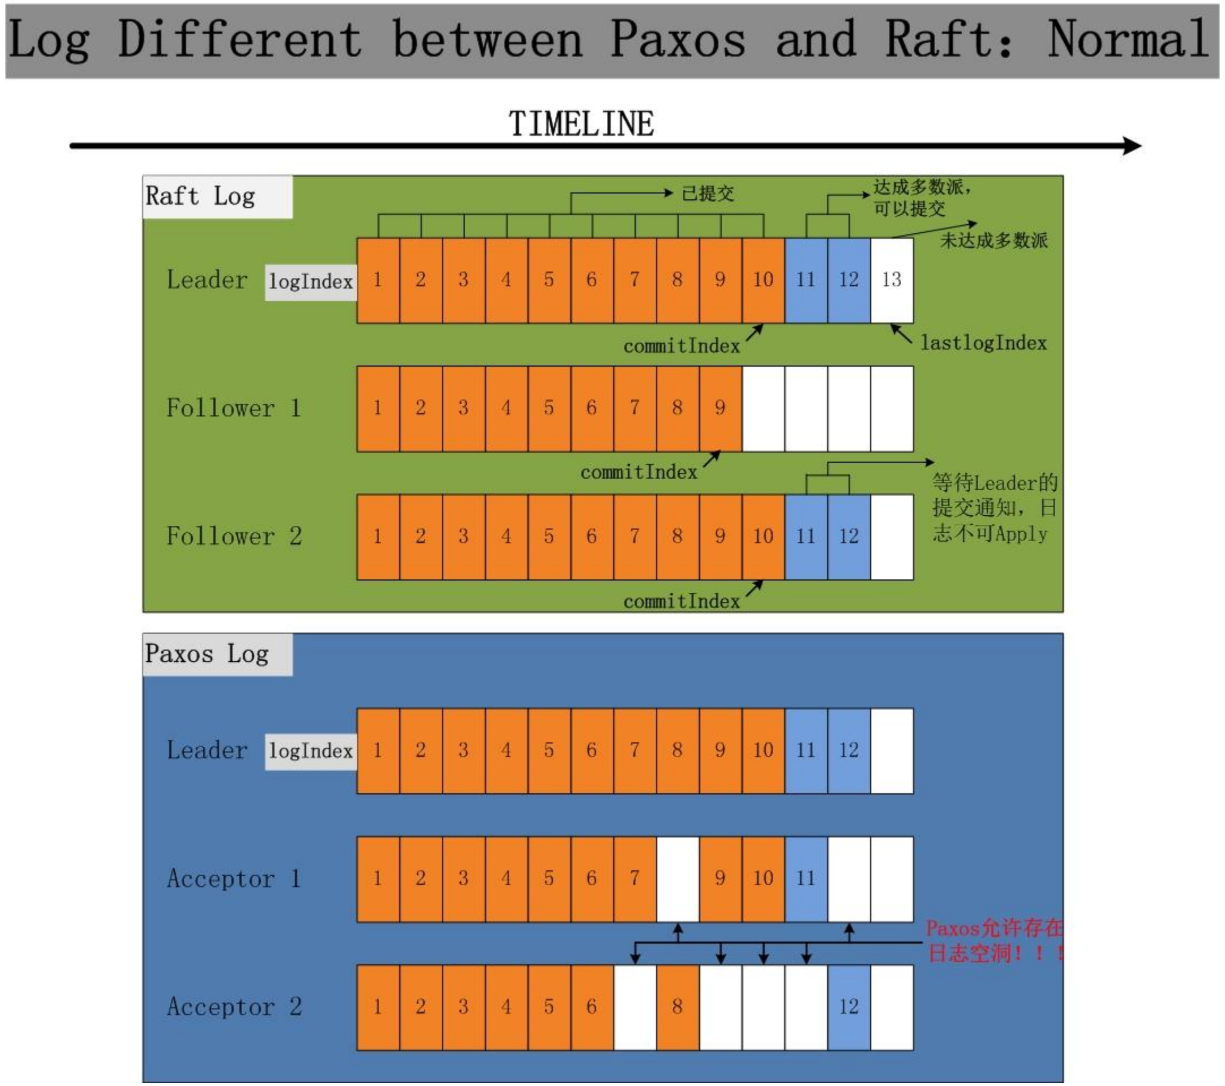

✓Multi-Paxos与Raft，在日志同步上最大的不同

- ✓ Raft需要日志连续，Multi-Paxos**允许日志空洞存在**

Raft——Commit Index推进

✓CommitIndex？

- ✓ 日志被复制到Followers之后，先持久化，并不能马上被应用
- ✓ 只有Leader知道日志是否达成多数派，是否可以应用（提交）
- ✓ 所谓的CommitIndex，就是已经达成多数派，可以应用的最新日志位置
- ✓ Followers记录当前的CommitIndex，所有小于等于CommitIndex的日志可以应用到状态机，所有大于CommitIndex的日志不能应用
- ✓ CommitIndex（TermID，LogIndex）

✓CommitIndex推进？

- ✓ 在当前日志达成多数派之后，Leader在下一个AppendEntries RPC中，将当前CommitIndex信息发送到所有的Followers
- ✓ Followers日志有效性检查，接受AppendEntries RPC，则同时更新本地的CommitIndex。若检查不通过，拒绝AppendEntries RPC，则同样不更新本地CommitIndex

Ra

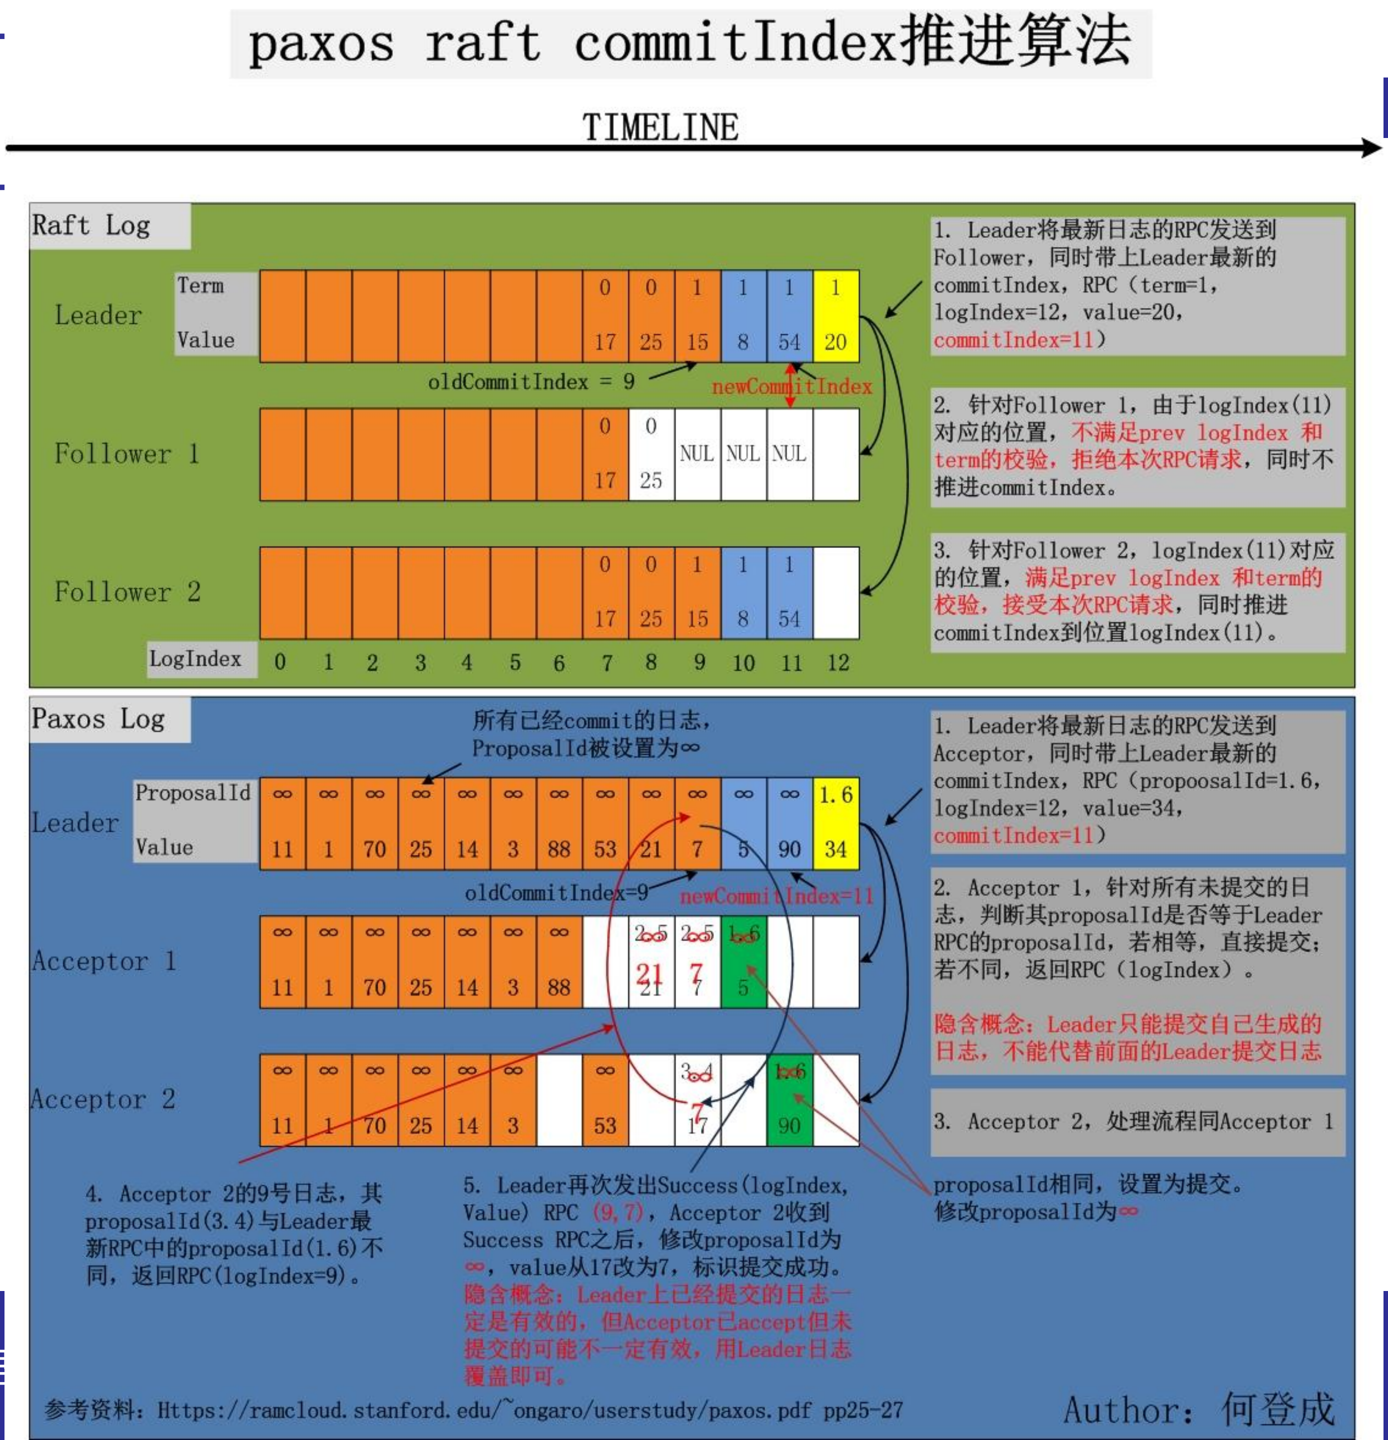

✓**Raft vs Multi-Paxos**

- ✓ Raft：日志连续的特性，确保CommitIndex推进逻辑非常简单
- ✓ Paxos：日志空洞，ComitIndex处理逻辑较复杂

Raft——AppendEntries RPC小结

✓**AppendEntries RPC**

- ✓ 完整信息：（currentTerm，logEntries，prevTerm，prevLogIndex，commitTerm，commitLogIndex，currentTimeStamp）
- ✓ **currentTerm，logEntries**：需要同步的日志
- ✓ **prevTerm，prevLogIndex**：Follower日志有效性检查
- ✓ **commitTerm，commitLogIndex**：当前日志的最新提交位点
- ✓ **currentTimeStamp**：心跳时间

Raft——Leader Crash

✓**Leader Crash**

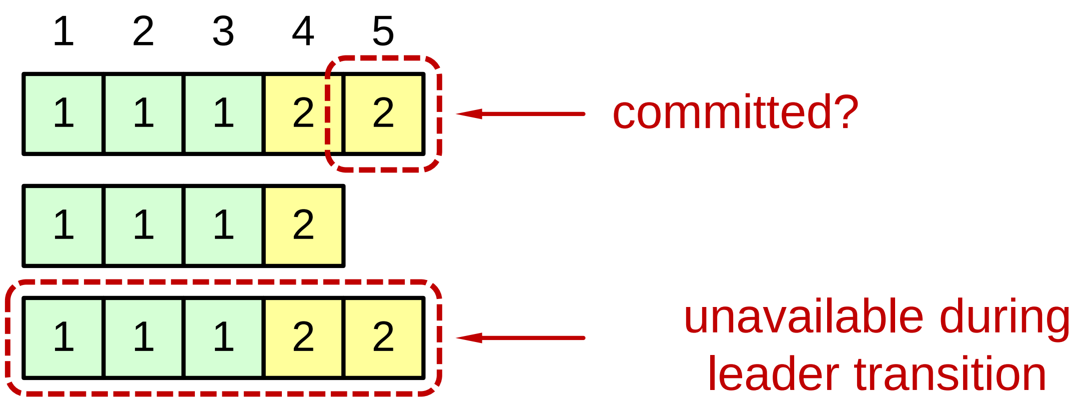

✓**New Leader选取原则**

- ✓ **最大提交原则**： During elections, choose candidate with log most likely to contain all committed entries

- ✓ Voting server V denies vote if its log is “more complete”：

  $(lastTerm_V > lastTerm_C)$ ||
  $(lastTerm_V == lastTerm_C)$ && $(lastIndex_V > lastIndex_C)$

Raft——Leader Crash（一个特殊场景）

✓**Committing Entry from Earlier Term**

- ✓ Term 1 Leader： s_1
- ✓ Term 2 Leader： s_2
- ✓ Term 3 Leader： s_5
- ✓ Term 4 Leader： s_1

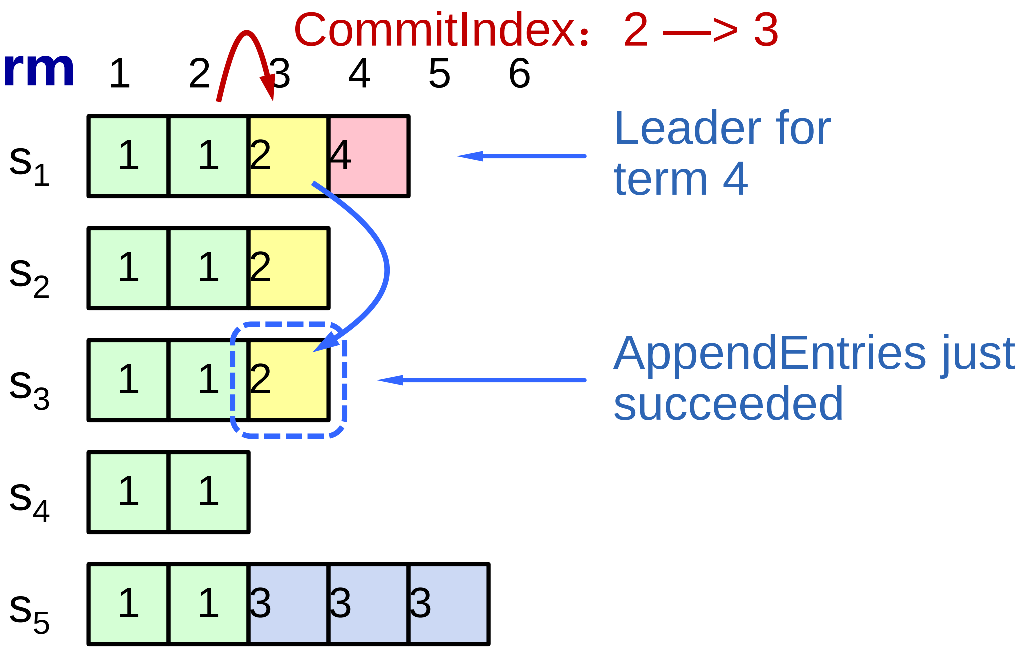

✓**New Leader提交原则**

- ✓ New Leader只能提交属于自己Term的日志，不能主动帮之前的Term提交（Advance CommitIndex）
- ✓ Why？

✓考虑如下场景：Term 4提交了LogIndex 3（Term 2），此时S1再次Crash，S5被重新选为主。S5重新提交LogIndex 3（Term 3），Term 2被覆盖，违背Consensus协议原则

Raft——Leader Crash（一个特殊场景：修复）

✓**New Leader提交原则**

- ✓ New Leader只能提交属于自己Term的日志，**不能主动**帮之前的Term提交

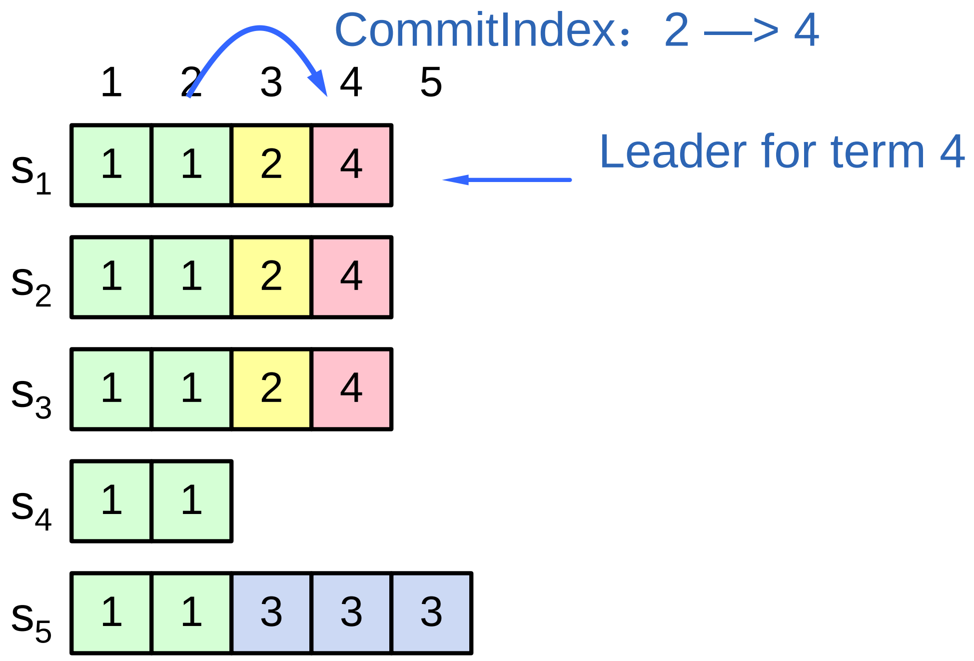

✓**不能主动提交，被动提交如何？**

- ✓ New Leader在写入新日志之后，直接将CommitIndex从LogIndex 2推进到LogIndex 4，**隐式提交**了LogIndex 3
- ✓ 此时，若S1再次Crash，S5不会被选为新主，因为其Term（3）小于已经达成多数派的Term（4）

Raft——Leader Stic

✓右图所示

- ✓ 第一阶段：5节点系统正常工作
- ✓ 第二阶段，Leader Network Partition，系统进入重新选主
- ✓ 第三阶段，节点2选主成功，系统恢复正常运行
- ✓ 第四阶段，节点1 Network Partition消除，重新加入。由于其TermID大于当前系统TermID，新主Stepdown，系统需要重新选主

✓Leader Stickiness

- ✓ 消除节点加入正常服务集群后，正常服务集群Leader被抢占

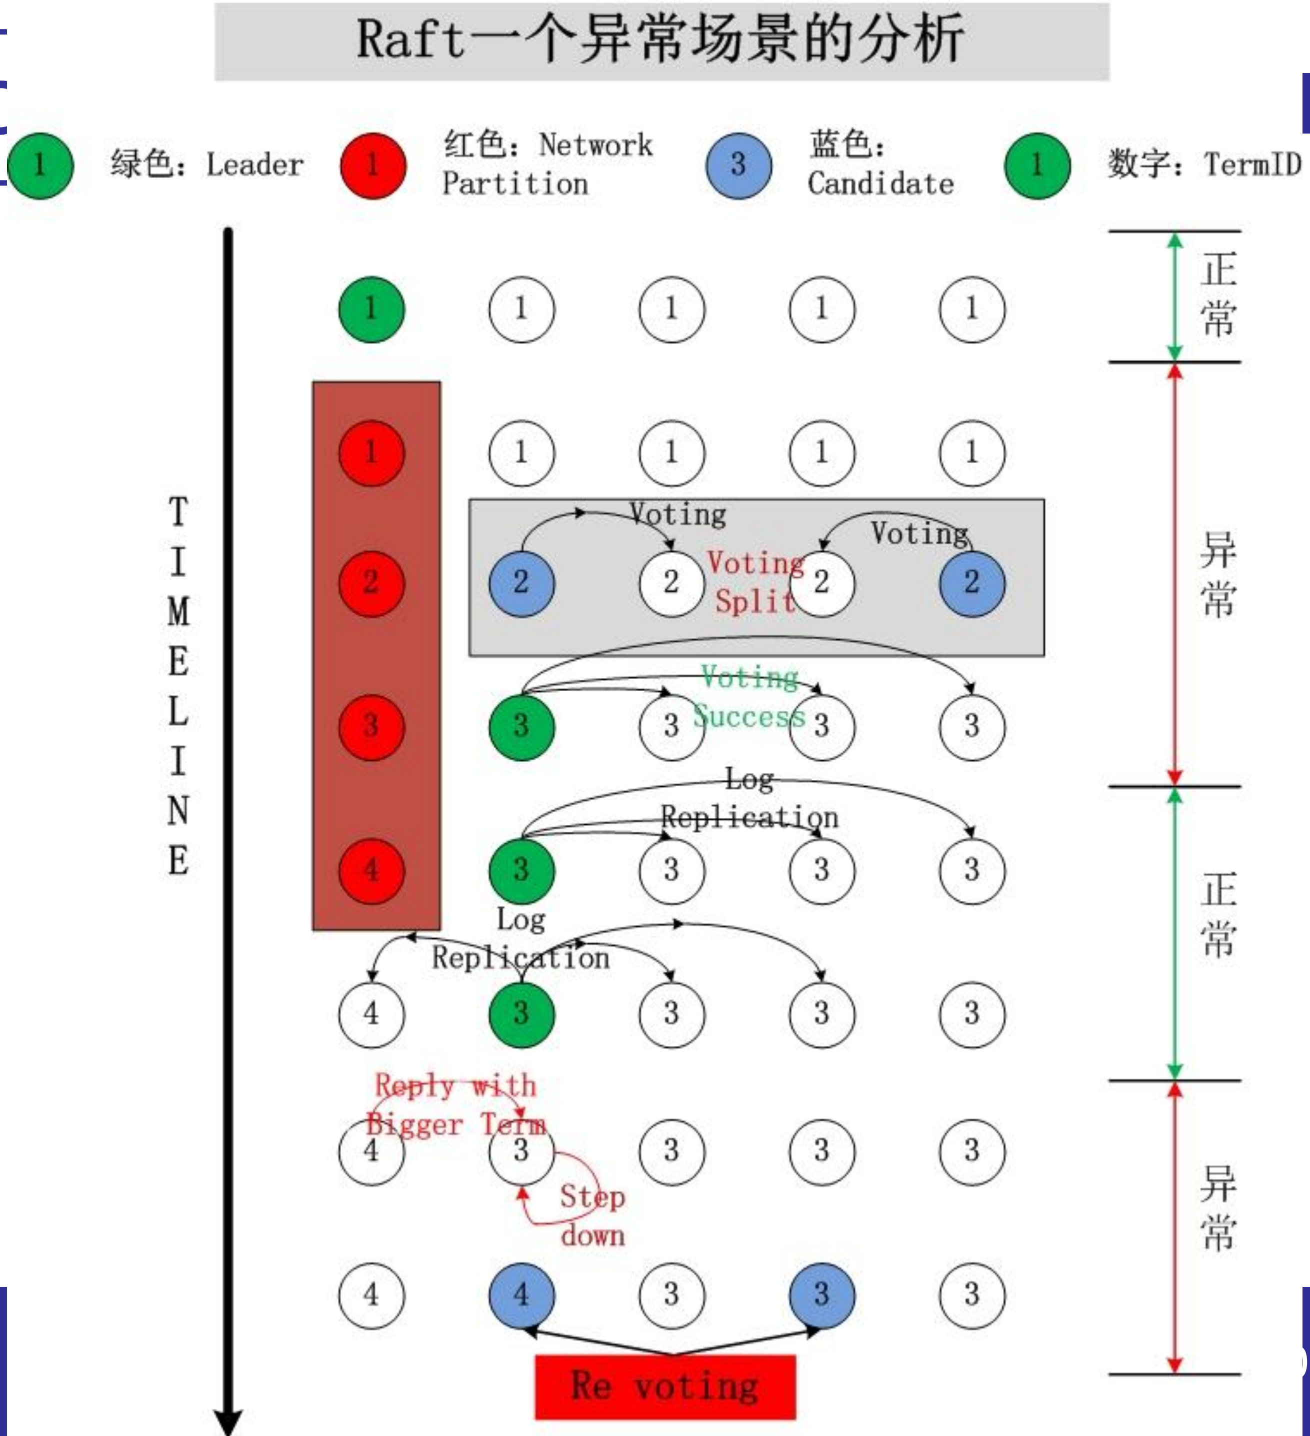

Raft——Leader Stickiness

✓Term Inflation

- ✓ Network Partition节点，由于跟集群失联，不断地试图选择自己为Leader，增加本地的Term ID
- ✓ 待Network Partition消除，节点重新加入集群，其Term已经远远大于正常集群的Term，导致集群无法正常服务，Leader Stepdown

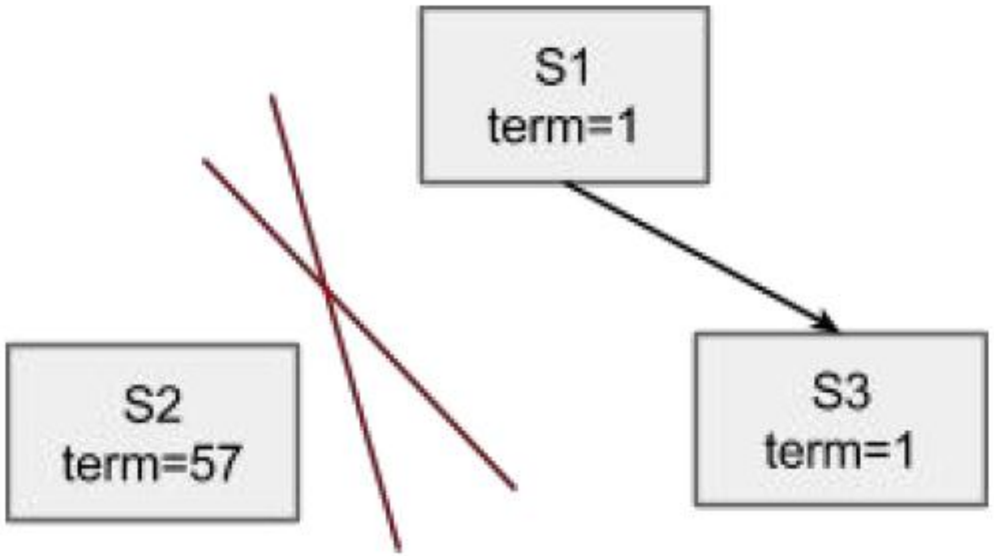

✓Pre-Vote

- ✓ 新增Pre-Vote RPC（currentTerm+1，lastLogIndex，lastLogTerm）
- ✓ 不修改Server的任何状态
- ✓ Pre-Vote RPC多数派返回成功，增加本地Term，将节点状态转换为Candidate，发出真正的Vote RPC
- ✓ 分区后的节点，Pre-Vote不会成功，Term不会增加。新加入也就不会导致集群无法正常服务

Ra

✓Le

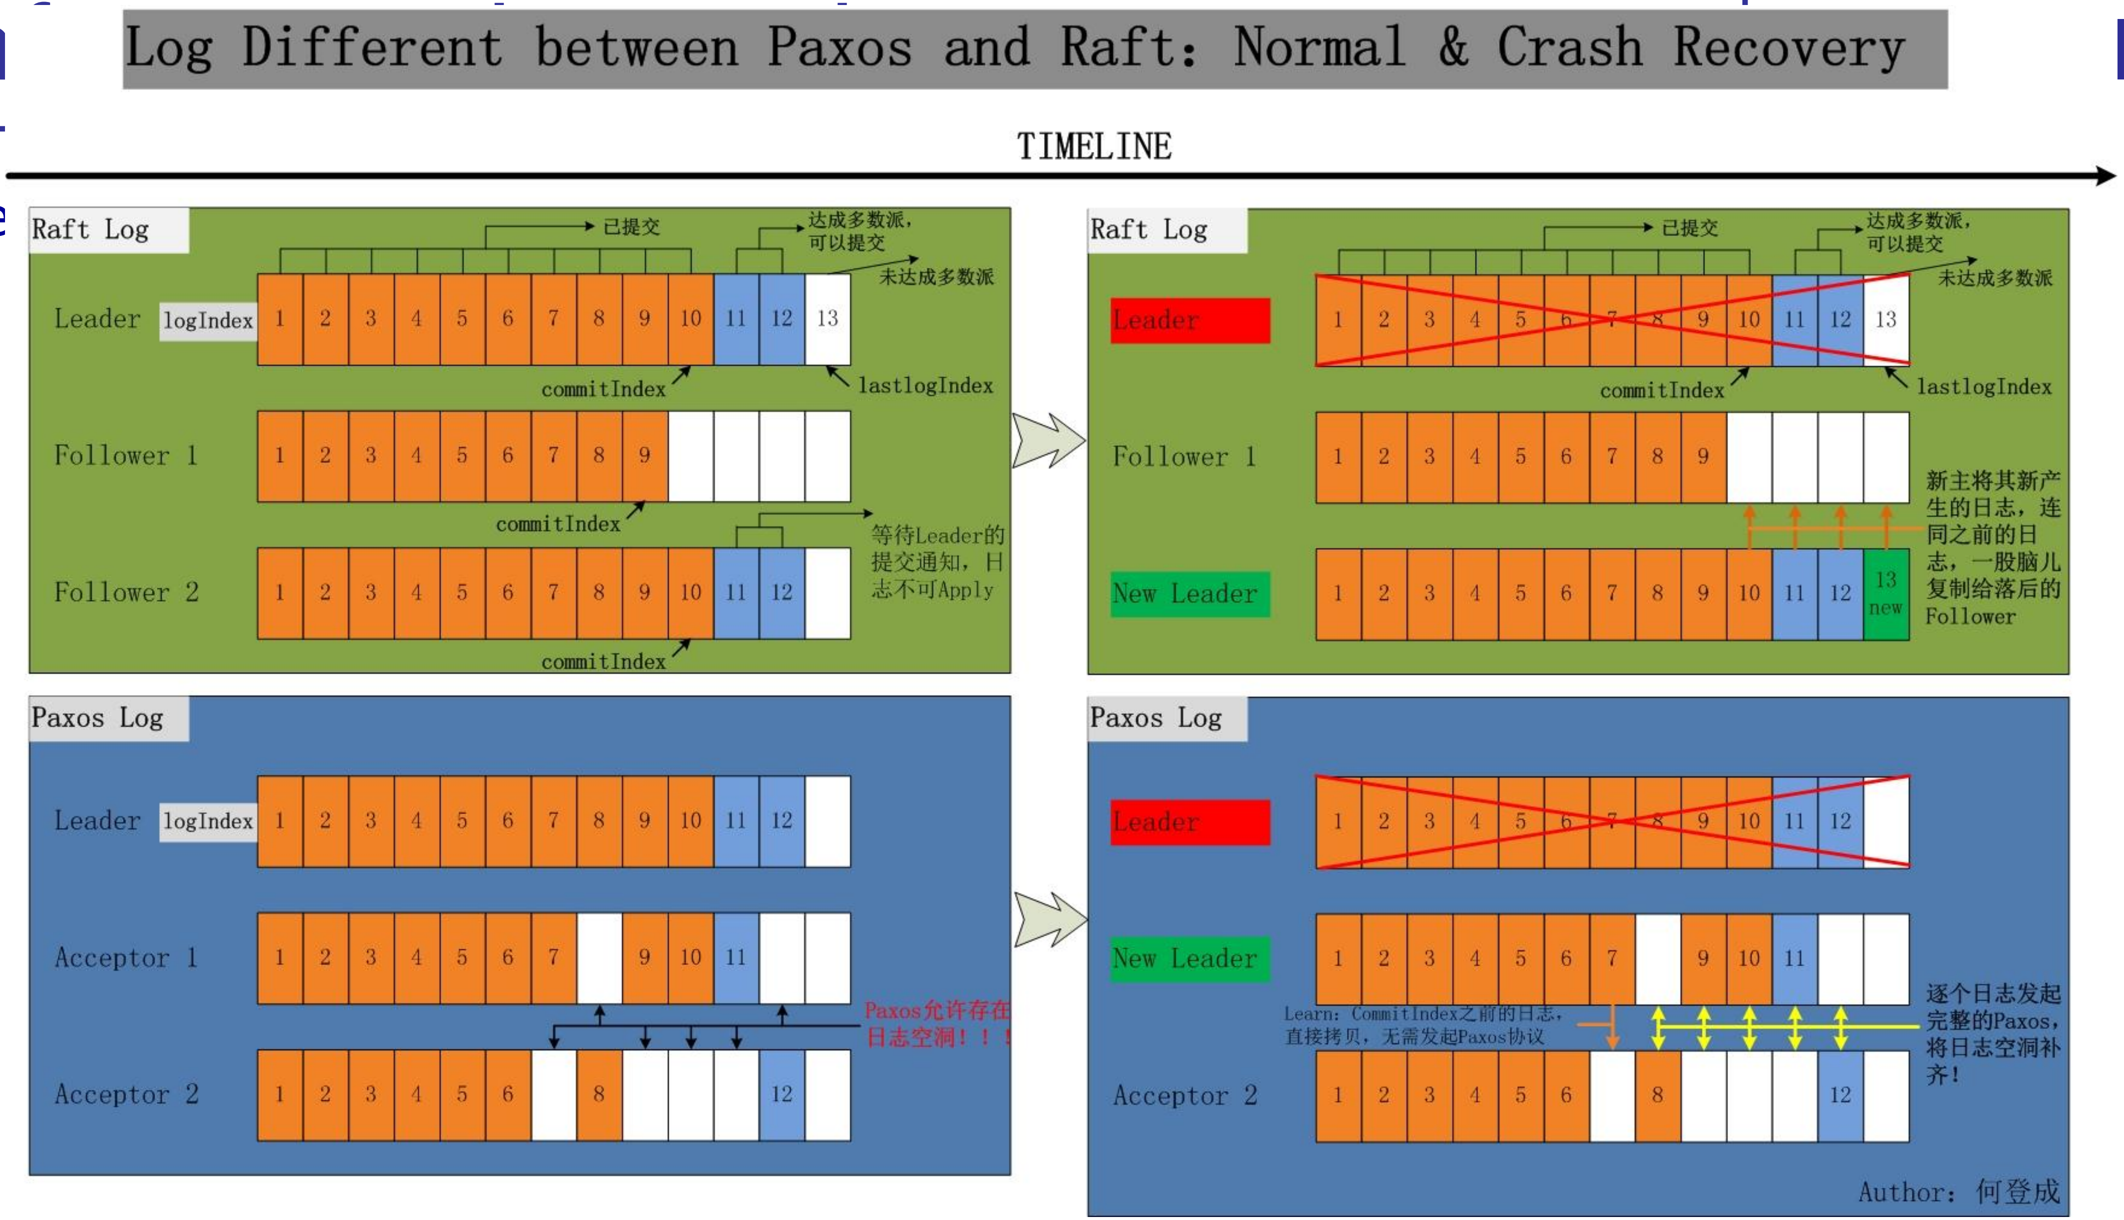

Log Different between Paxos and Raft: Normal & Crash Recovery
TIMELINE
Raft Log
已提交
达成多数派，可以提交
未达成多数派
Leader
logIndex
commitIndex
lastlogIndex
Follower 1
commitIndex
Follower 2
等待Leader的提交通知，日志不可Apply
commitIndex
Raft Log
已提交
达成多数派，可以提交
未达成多数派
Leader
commitIndex
lastlogIndex
Follower 1
新主将其新产生的日志，连同之前的日志，一股脑儿复制给落后的Follower
New Leader
13 new
Paxos Log
Leader
logIndex
Acceptor 1
Paxos允许存在日志空洞！！！
Acceptor 2
Paxos Log
Leader
New Leader
Learn：CommitIndex之前的日志，直接拷贝，无需发起Paxos协议
逐个日志发起完整的Paxos，将日志空洞补齐！
Acceptor 2
Author：何登成

Raft vs Multi-Paxos：Leader Crash

- ✓**Raft**
  - ✓ 必须选择拥有最多最新日志的Follower，作为新Leader
  - ✓ 新Leader上任之后，自己的日志是最全的准确的（根据Leader选取原则），直接覆盖Follower的即可
- ✓**Multi-Paxos**
  - ✓ 可选择任意节点作为新Leader
  - ✓ 新Leader上任之后
    - ✓ 获取当前节点的CommitIndex
    - ✓ 获取整个系统中所有节点的MaxIndex
    - ✓ 本节点CommitIndex之前的日志，可直接复制给Acceptors
    - ✓ [CommitIndex, MaxIndex]之间的每一条日志，需要逐个应用Basic Paxos，确定该选择哪一个LogEntries
    - ✓ MaxIndex之后的所有日志，在Leader选举阶段就完成了一次Prepare，后续直接Accept即可

Raft——Membership Change

✓**Membership Change**

- ✓ **包括**：系统中，节点增加、删除、替换
- ✓ **不包括**：节点Crash、Crash节点重启加入
  - ✓ Raft设计，就是允许少数派节点Crash，不影响系统的可用性

✓**Membership Change设计目标**

- ✓ Online Membership Change，过程不影响系统的持续可用

Raft——Men

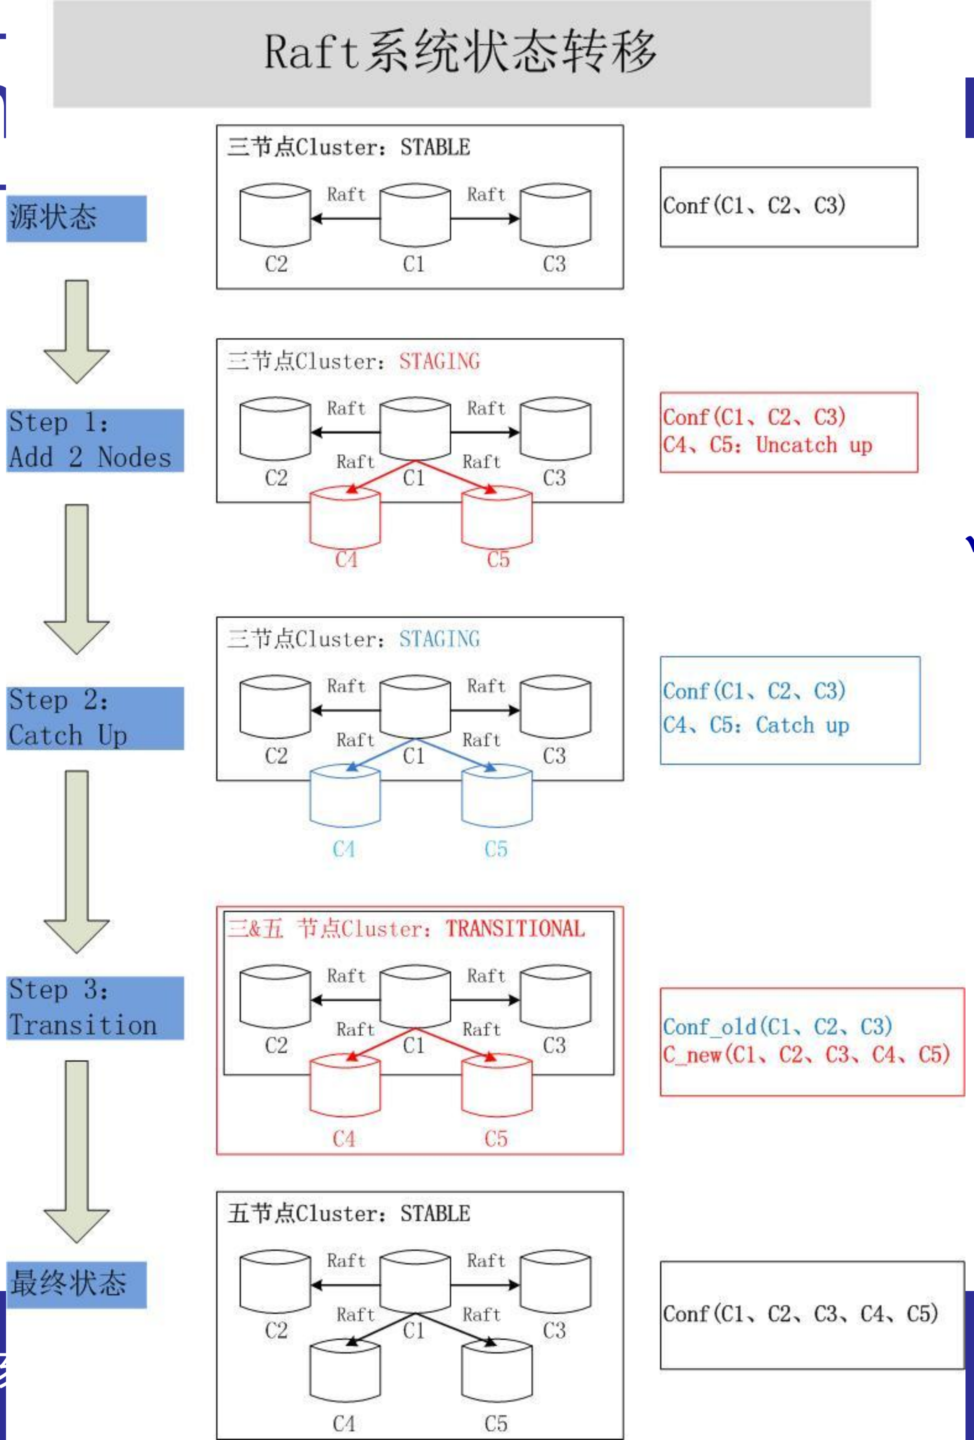

✓**Step 3：Transitional Stage**

- ✓ Conf_old、Conf_new两个Configuration Group，需要同时达成多数派，Log Replication才算是成功

✓**Online Membership Change（关键词）**

- ✓ 系统状态变化同样通过日志同步
- ✓ 新老配置共存平滑过度
- ✓ 一次可变更多个Member（Add/Remove）

Raft/Multi-Paxos：阶段总结

✓**Now，what we learn？**

- ✓ 学会了Raft/Multi-Paxos，能用来解决连续Consensus问题，确定连续多个提案，确保系统各节点状态完全一致
- ✓ 学会了自动化的Leader Election，保证系统在少数派宕机下的持续可用
- ✓ 学会了日志强同步，保证系统在Leader宕机后的零数据丢失
- ✓ 实现所有上面这些功能，都是自封闭的，零外部系统依赖

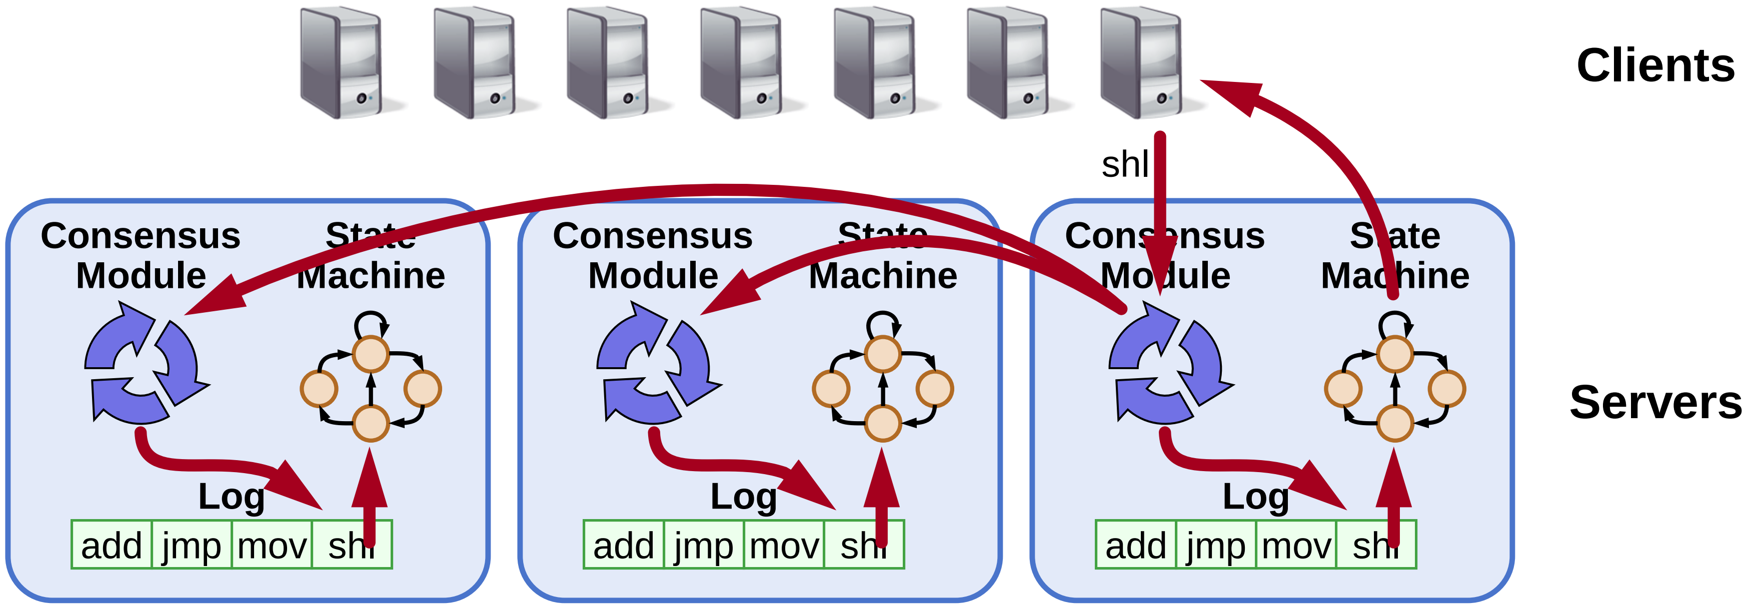

Raft vs Multi-Paxos 小结

- ✓**Paxos的核心，在Basic Paxos，关于Multi-Paxos缺乏太多的理论论证。**
- ✓**Raft则将Multi-Paxos的功能做了模块划分，并对每个模块做了详细的阐述和理论证明**
  - ✓ Leader Election、Log Replication、Commit Index Advance、Crash Recovery、Membership Change 等

- ✓**Multi-Paxos和Raft，最本质的区别，在于是否允许日志空洞。Raft必须连续，不允许空洞。Multi-Paxos允许日志空洞存在**
  - ✓ **允许空洞**：Paxos应对复杂网络环境，更为鲁棒（以三副本为例）
    - ✓ 三节点两两不连通：Raft、Paxos均无法工作
    - ✓ 两个Followers与Leader间的网络，短时间内轮询连接震荡：Paxos不受影响，Raft会受部分影响
    - ✓ 除此之外，Raft、Paxos的表现无差别，均可持续正常服务
  - ✓ **不允许空洞**：Raft在Log Replication、Crash Recovery、CommitIndex Advance 等模块的算法实现上，更为简单

Paxos/Multi-Paxos/Raft能干什么？

- Google Chubby
- Zookeeper
- MegaStore
- Spanner

- ETCD
- CockRoachDB
- MongoDB
- OceanBase
- … …

Paxos/Multi-Paxos/Raft能干什么？

✓Multi-Paxos/Raft功能回顾

- ✓ **系统各节点状态强一致**
- ✓ 系统少数派宕机，不影响可用性（持续可用）
- ✓ 系统本身功能自封闭，零外部系统依赖

✓作为大型系统的Build Block

- ✓ MegaStore、Spanner、CockRoachDB、TiDB …

✓作为基础系统对外提供服务

- ✓ 服务种类：服务发现、分布式锁服务、配置中心（元数据管理）、集群管理（Leader Election） …
- ✓ 服务产品：Zookeeper、ETCD …

- ✓ 所有服务的本质，就是Server状态机中的一个状态变更，通过Paxos/Raft来保证状态变更全局一致和高可用

Example：ETCD

✓基于Raft协议实现的，提供服务发现和配置管理的高可用键值系统

etcd

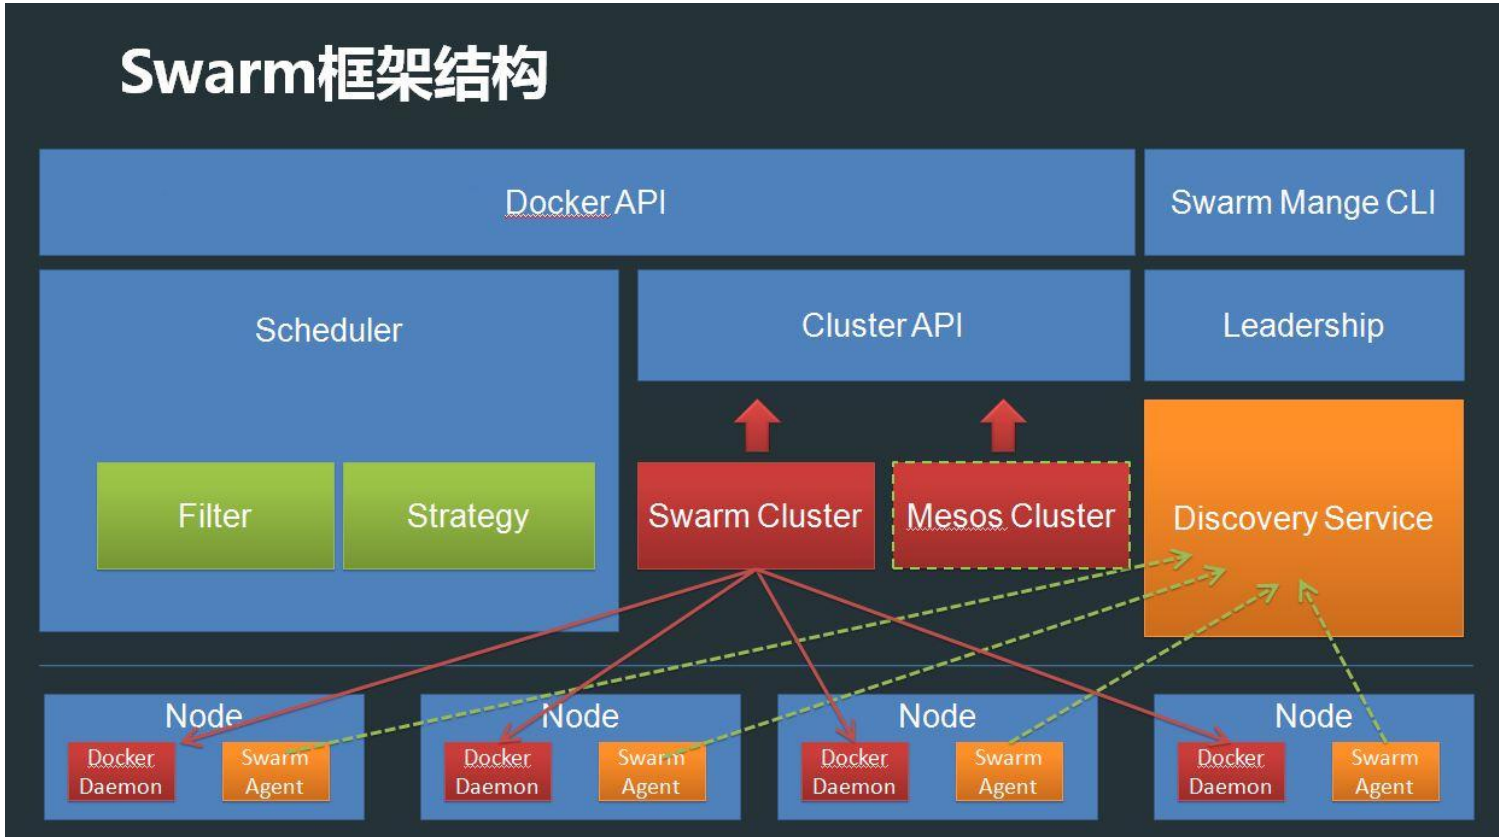

✓**功能接口**
- ✓ Write a key、Read keys
- ✓ Watch key changes
- ✓ Grant leases
- ✓ …

✓**使用场景**

广告时间

- ✓Ali Consensus（目标）
  - ✓ **全功能的Consensus算法实现**
    - ✓ 各节点状态强一致
    - ✓ 持续可用
    - ✓ 零外部系统依赖
  - ✓ **高性能**
    - ✓ 全异步
    - ✓ 批处理
  - ✓ **模块化**
    - ✓ Ali Consensus可以模块化输出

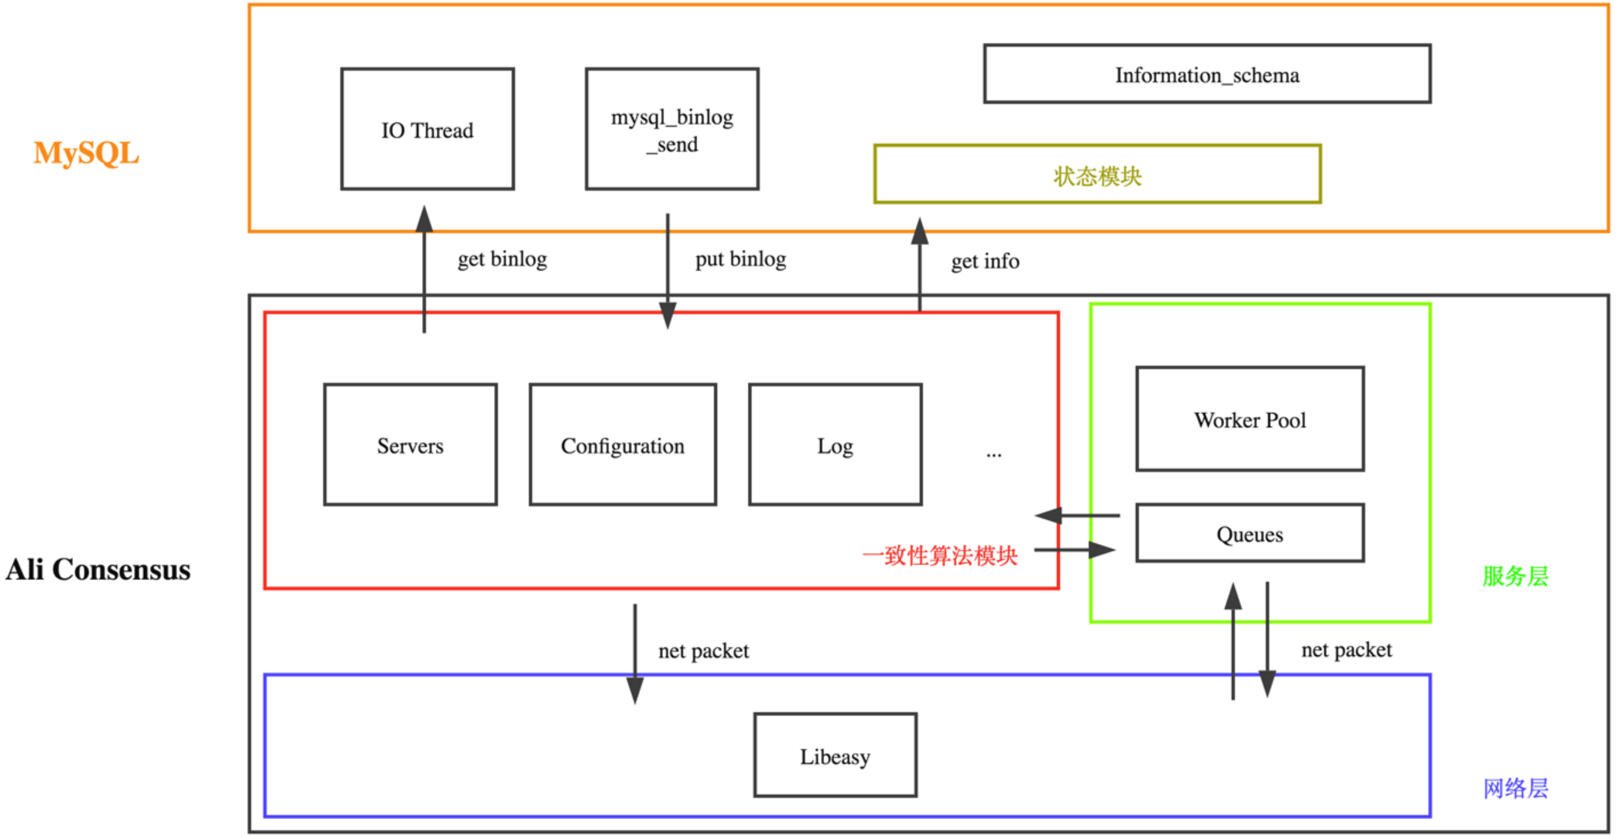

广告时间

- ✓**数据库内核产品**
  - ✓ 8月初，Ali Consensus模块一期开发完毕
  - ✓ 9月中旬，基于RocksDB的三副本强同步交付
    - ✓支持put/get接口
  - ✓ 11月初，基于AliSQL的三副本强同步交付
    - ✓支持复杂的SQL语句

```
$./test_main 2
Index: 2 .
TS:1470899242. 19328 Server 2 : isVote: 1, requestServer: 2, term: 1 lli:0, llt:0
TS:1470899243. 20208 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899244. 20144 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899245. 20200 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899246. 20190 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899247. 20201 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899248. 20195 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899249. 20153 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899250. 20195 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899251. 20185 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899252. 20189 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899253. 20186 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899254. 20154 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899255. 20139 Server 2 : revice logs from leader(1), msg.term(1)
TS:1470899262.626284 Server 2 : become Leader (currentTerm 2)!!
```

```
$./test_main 2
Index: 2 .
TS:1470899294.373406 Server 2 : revice logs from leader(3), msg.term(3)
TS:1470899295.373215 Server 2 : revice logs from leader(3), msg.term(3)
TS:1470899296.373216 Server 2 : revice logs from leader(3), msg.term(3)
TS:1470899297.373233 Server 2 : revice logs from leader(3), msg.term(3)
TS:1470899298.373220 Server 2 : revice logs from leader(3), msg.term(3)
TS:1470899299.373226 Server 2 : revice logs from leader(3), msg.term(3)
```

参考资料

✓Diego Ongaro and John Ousterhout. In Search of an Understandable Consensus Algorithm.
✓Tushar Chandra. Paxos Made Live - An Engineering Perspective.
✓Jason Baker. Megastore: Providing Scalable, Highly Available Storage for Interactive Services.
✓JAMES C. CORBETT. Spanner: Google’s Globally Distributed Database.
✓Mike Burrows. The Chubby lock service for loosely-coupled distributed systems.
✓Diego Ongaro and John Ousterhout. Raft: A Consensus Algorithm for Replicated Logs.
✓John Ousterhout and Diego Ongaro. Implementing Replicated Logs with Paxos.
✓李凯. 架构师需要了解的Paxos原理、历程及实战.
✓The Secret Lives of Data. Raft Understandable Distributed Consensus.
✓raft github. The Raft Consensus Algorithm.
✓Henrik Ingo. Four modifications for the Raft consensus algorithm.
✓Jason Wilder. Docker Service Discovery Using Etcd and Haproxy.
✓Jason Wilder. Open-Source Service Discovery.
✓线超博. DockOne技术分享（二十）：Docker三剑客之Swarm介绍.
✓陌辞寒. Zookeeper和etcd使用场景.

致谢

谢谢大家！